UNIVERSIDAD MAYOR DE SAN ANDRÉS

FACULTAD DE CIENCIAS PURAS Y NATURALES

CARRERA DE INFORMÁTICA



Caso de estudio 2

PROYECTO APRENDIZAJE NO SUPERVISADO DE INTELIGENCIA URBANA Y PATRONES CRIMINALES MEDIANTE CLUSTERING ESPACIOTEMPORAL, MODELADO PROBABILÍSTICO Y MINERÍA SEMÁNTICA

INTEGRANTES:

- Arias Cruz, Julio Nelson
- Cordova Avendaño, Yoshua Aaron
- Serrano Mamani, Raquel Araceli

ASIGNATURA: DAT 255 - Aprendizaje Automático

DOCENTE: Menfy Morales

La Paz – Bolivia

Índice

ÍNDICE GENERAL II

ÍNDICE DE FIGURAS IV

ÍNDICE DE TABLAS VI

1. INTRODUCCIÓN 1

2. ANTECEDENTES 2

3. PROBLEMÁTICA 3
3.1. Árbol de Problemas del Conjunto de Datos de Chicago . . . 3
3.2. Árbol de Problemas del Conjunto de Datos de Bolivia . . . 5

4. OBJETIVOS 7
4.1. Objetivo Principal . . . 7
4.2. Objetivos Específicos . . . 7
4.3. Árbol de Objetivos . . . 8

5. JUSTIFICACIÓN 9
5.1. Árbol de Objetivos: Medios y Fines . . . 9

6. MARCO TEÓRICO 10
6.1. Diccionario de Datos: Inteligencia Urbana y Criminalidad . . . 11
6.1.1. Diccionario Original (Fuentes en Bruto) . . . 11
6.1.2. Diccionario de Datos Después de la Limpieza y Preprocesamiento . . . 12
6.1.3. Mapeo Departamental y Ecosistema de Medios Informativos de Bolivia 12
6.2. Algoritmos No Supervisados Aplicados . . . 12
6.2.1. K-Means Particional y Variantes Semánticas . . . 15
6.2.2. DBSCAN con Métrica Geodésica de Haversine . . . 15
6.2.3. HDBSCAN: Clustering Jerárquico por Densidad y Persistencia . . . 15
6.2.4. OPTICS: Diagrama de Alcanzabilidad y Detección de Valles . . . 16
6.2.5. Gaussian Mixture Models (GMM) y Esperanza-Maximización (EM) . 16
6.2.6. Clustering Jerárquico Aglomerativo (Ward) . . . 17
6.2.7. Reducción de Dimensionalidad (PCA, SVD, PPCA, t-SNE, UMAP) . 17
6.2.8. Autoencoders Neuronales para Detección de Anomalías . . . 18
6.2.9. Modelado de Tópicos con Latent Dirichlet Allocation (LDA) . . . 18

7. METODOLOGÍA 19
7.1. Fuente de Datos . . . 19
7.2. Tareas de Modelado No Supervisado . . . 19
7.3. Desarrollo de la Limpieza de Datos . . . 20
7.3.1. Auditoría y Perfilado de los Datos . . . 20

7.3.2. Normalización y Estandarización de Formatos 20
7.3.3. Gestión de Registros Duplicados y Amontonamiento Coordenado (Stacking) 21
7.3.4. Tratamiento de Valores Faltantes 21
7.3.5. Tratamiento de Valores Atípicos Espaciales 22
7.3.6. Resultado y Balance de la Limpieza 22
7.4. Validación Cruzada y Análisis de Complejidad de Hiperparámetros 22

8. MARCO PRÁCTICO 23
8.1. Análisis de Exploración de Datos (EDA) 23
8.1.1. Carga y Vista General (Dimensiones, Tipos de Dato y Nulos) 23
8.1.2. Estadística Descriptiva de Variables Numéricas y Espaciales 23
8.1.3. Análisis de Variables Categóricas 24
8.1.4. Análisis Temporal (Mes, Hora y Estacionalidad Cíclica) 24
8.1.5. Análisis Geográfico y Cartografía de Densidad Espacial 25
8.1.6. Análisis Bivariado y Matriz de Correlación 25
8.1.7. Relación entre Tipos Criminales y Entornos Físicos (Boxplots) 25
8.1.8. Detección de Valores Atípicos Espaciotemporales (Outliers) 26
8.2. Modelo K-Means Particional y Minería Semántica NLP 26
8.3. Modelo DBSCAN con Métrica Haversine y Benchmark de Densidad 27
8.4. Modelo HDBSCAN Multiescala y Persistencia Lambda 29
8.5. Modelo OPTICS y Diagrama de Alcanzabilidad (Reachability Plot) 30
8.6. Modelo Gaussian Mixture Models (GMM) y Elipses de Covarianza 31
8.7. Modelo Clustering Jerárquico Aglomerativo (Ward) 33
8.8. Modelos de Reducción de Dimensionalidad (PCA, SVD, PPCA, t-SNE, UMAP) 34
8.9. Modelo Autoencoder Neuronal para Detección de Anomalías 35
8.10. Modelo de Asignación de Tópicos Latentes (LDA) 38
8.11. Análisis Comparativo Multimodelo (A/B Testing de Clustering y Métricas) . 38

9. HERRAMIENTAS Y TÉCNICAS 41

10. RESULTADOS 42
10.1. Plataforma Web Master y Consola Ejecutiva 42
10.2. Segmentación Cartográfica y Visor 3D WebGL 42
10.3. Partición Semántica y Clasificación de Modus Operandi en Tiempo Real . . 43

11. ARQUITECTURA DEL SISTEMA 46
11.1. Descripción Funcional de las Capas 46

12. CONCLUSIONES 49

13. RECURSOS Y ENLACES DEL PROYECTO 51

APÉNDICES 51

REFERENCIAS BIBLIOGRÁFICAS 55

Índice de figuras

1. Árbol de Problemas del Conjunto de Datos de Chicago. . . . 4
2. Árbol de Problemas del Conjunto de Datos de Bolivia. . . . 6
3. Árbol de Objetivos del Proyecto de Inteligencia Urbana y Criminología Computacional. . . . 8
4. Proyección Bidimensional del Espacio Semántico Reducido LSA Mediante TruncatedSVD. . . . 18
5. Panel Táctico de Calibración Espacial y Detección de Hotspots en The Loop. 21
6. Evaluación Multivariable de Hiperparámetros K-Means: Codo, Coeficiente Silhouette y Davies-Bouldin. . . . 26
7. Validación Cruzada y Matriz de Contingencia entre K-Means (Particional) y Enlace de Ward (Jerárquico). . . . 27
8. Comparador Tri-Modelo de Densidad Espacial (DBSCAN, HDBSCAN y OPTICS) sobre Chicago Distrito 1. . . . 28
9. Hallazgos Clave de Auditoría Espacial: Cobertura, Rescate de Eventos y Duplicados de Geocodificación. . . . 29
10. Dendrograma condensado de estabilidad y persistencia de clústeres en HDBSCAN. . . . 30
11. Diagrama de Alcanzabilidad de OPTICS con identificación de valles de densidad. 30
12. Elipses de Covarianza Multivariantes Gaussianas (GMM) a Escala Urbana en Santa Cruz. . . . 32
13. Superficie de Densidad Continua GMM y Muestreo Táctico por Sonda Espacial. 32
14. Dendrograma Jerárquico Aglomerativo (Ward) y Clustermap de Sectores Urbanos de Bolivia. . . . 33
15. Perfiles Operacionales y Diagramas Radiales por Macro-Grupo Taxonómico ($k = 3$). . . . 34
16. Plano Bidimensional PCA Coloreado por Macro-Conglomerados Jerárquicos de Ward. . . . 35
17. Plano Bidimensional PCA Coloreado por Tipología Penal Específica. . . . 36
18. Plano Bidimensional PCA Coloreado por Tópicos Latentes de Dirichlet (LDA). 36
19. Consola de Detección de Anomalías por Autoencoder y Umbral Crítico P90. 37
20. Fichas Técnicas de Noticias Anómalas Aisladas con Error de Reconstrucción Exacto. . . . 38
21. Panel de Control del Modelado de Tópicos Latentes (LDA) y Métricas de Coherencia. . . . 39
22. Prevalencia de Tópicos en el Corpus Documental y Matriz de Separación Semántica. . . . 40
23. Consola Ejecutiva de la Plataforma CPD Analytics Core (Urban Intelligence v4.8). . . . 43
24. Visor Esférico 3D Globo en WebGL a 985 km de Altitud Orbital. . . . 44
25. Delimitación Cartográfica 3D de Hotspots Urbanos mediante DBSCAN Geodésico. . . . 44
26. Visualización de Valles de Densidad Jerárquica en Modo OPTICS 3D. . . . 45

27. Auditoría Táctica de Incidentes a Nivel Urbano en La Paz mediante Enlace de Ward. 45
28. Inferencia Semántica NLP de Modus Operandi y Diagnóstico Táctico en Tiempo Real. 46
29. Proyector de Dirichlet en Vivo sobre Reportes Criminalísticos Emergentes. . 47
30. Explorador del Corpus Documental de Noticias Etiquetado Automáticamente por Tópicos LDA. 47
31. Diagrama de Arquitectura Modular del Sistema en Cuatro Capas. 48
32. Diseño esquemático de la consola del visor cartográfico interactivo Globo 3D en WebGL. 55

Índice de tablas

1. Diccionario de variables estructuradas listas para modelado no supervisado. . 13
2. Ecosistema de medios y fuentes periodísticas georreferenciadas de Bolivia. . . 14
3. Resumen del balance del pipeline de depuración y preparación de datos. . . . 22
4. Estadística descriptiva de las variables operativas y espaciales del dataset. . . 24
5. Métricas operativas del modelo DBSCAN con distancia geodésica de Haversine. 28
6. Parámetros estimados por el algoritmo EM para las cuatro mixturas gaussianas. 31
7. Matriz de correlación penal (% normalizado) y estabilidad bootstrap por sector territorial. 33
8. Comparativa técnica de métodos de reducción de dimensionalidad. 34
9. Tópicos latentes descubiertos por el modelo Latent Dirichlet Allocation (LDA). 39
10. Tabla comparativa global de métricas de calidad entre algoritmos de clustering. 40
11. Catálogo de endpoints y microservicios REST de la plataforma analítica. . . 49

1. INTRODUCCIÓN

La criminalidad urbana y los incidentes que vulneran la seguridad ciudadana constituyen fenómenos sociotécnicos altamente dinámicos, heterogéneos y multidimensionales. Su impacto directo sobre la integridad física de las personas, el bienestar colectivo, la actividad económica y el desarrollo urbano exige que las instituciones de control, monitoreo y planificación formulen estrategias de respuesta y prevención basadas en evidencia empírica rigurosa. En este escenario, la recopilación sistemática de reportes policiales, llamadas de emergencia y crónicas periodísticas ha originado grandes repositorios de datos espaciotemporales no etiquetados.

No obstante, la administración tradicional de la seguridad pública suele operar bajo esquemas reactivos, limitándose al análisis estadístico descriptivo agregado por divisiones político-administrativas rígidas (como distritos, cuadrantes o precintos policiales). Este enfoque tradicional presenta severas limitaciones metodológicas: ignora la continuidad espacial real del territorio, enmascara micro-concentraciones delictivas (*hotspots*) en las fronteras entre zonas, es incapaz de descubrir patrones emergentes de *modus operandi* en descripciones de texto libre y resulta ineficaz para detectar eventos delictivos atípicos o anomalías operativas que se diluyen en el volumen masivo de registros rutinarios.

Frente a este desafío, las técnicas de **Aprendizaje Automático No Supervisado** (*Unsupervised Machine Learning*) proveen un marco analítico y matemático idóneo para extraer estructuras latentes, segmentaciones intrínsecas y regularidades estadísticas sin requerir supervisión humana ni etiquetas preestablecidas. El presente proyecto desarrolla e implementa un sistema integral de inteligencia urbana y criminología computacional que articula múltiples paradigmas no supervisados:

- **Clustering Espacial Basado en Densidad:** Algoritmos DBSCAN, HDBSCAN y OPTICS formulados con la métrica geodésica de *Haversine* sobre la curvatura de la esfera terrestre, capaces de identificar agrupaciones delictivas de morfología arbitraria y separar formalmente el ruido estocástico de incidentes aislados.
- **Particionamiento Multivariable y Minería Semántica de Texto:** Integración de K-Means con codificación cíclica temporal (seno y coseno de horas y días) y vectorización de texto TF-IDF (*Term Frequency - Inverse Document Frequency*) para clasificar automáticamente narrativas de crímenes y descubrir arquetipos de *modus operandi*.
- **Modelado Probabilístico Continuo:** Mixturas de Gaussianas (GMM) ajustadas mediante el algoritmo Esperanza-Maximización (EM) y elipses de covarianza al 95.4 % (2σ) para modelar densidades suaves de riesgo.
- **Taxonomía Jerárquica Distrital:** Agrupamiento aglomerativo de enlace Ward que organiza los precintos urbanos según su huella criminal relativa.
- **Reducción de Dimensionalidad y Espacios Latentes:** Proyecciones lineales y no lineales (PCA, TruncatedSVD, PPCA, t-SNE y UMAP) para visualización de alta fidelidad.

- **Detección Neuronal de Anomalías:** Autoencoders profundos con arquitectura de cuello de botella (*bottleneck*) que aíslan crímenes excepcionales mediante el error cuadrático medio de reconstrucción (MSE).
- **Visualización Cartográfica Inmersiva 3D:** Un visor interactivo global WebGL (Globo 3D) que integra de manera dual el conjunto masivo de referencia internacional de Chicago (+800,000 registros) con el corpus georreferenciado de seguridad ciudadana de Bolivia (137 crónicas estructuradas de los nueve departamentos).

El documento expone a continuación el desarrollo conceptual, matemático, metodológico y práctico del sistema, fundamentado bajo el estándar de procesos CRISP-DM / ASUM-DM.

2. ANTECEDENTES

El análisis territorial y temporal de la delincuencia ha evolucionado profundamente desde los primeros mapas de alfileres (*pin maps*) utilizados por los departamentos de policía en el siglo XIX hasta las plataformas contemporáneas de inteligencia geoespacial asistidas por inteligencia artificial. Durante décadas, la criminología empírica descansó sobre postulados teóricos que explican la concentración delictiva en el espacio físico:

1. **Teoría de las Actividades Rutinarias Cohen and Felson (1979):** Propone que un delito ocurre cuando convergen en tiempo y espacio tres elementos fundamentales: un agresor motivado, un objetivo o víctima atractiva, y la ausencia de un guardián capaz. El movimiento cotidiano de la población define nodos de atracción delictiva.
2. **Teoría del Patrón Delictivo Brantingham and Brantingham (1993):** Establece que los infractores no eligen sus blancos de manera aleatoria, sino que exploran áreas familiares delimitadas por sus rutas de desplazamiento entre el hogar, el trabajo y las zonas de ocio, conformando corredores delictivos estructurados.
3. **Criminología Ambiental y Ley de Concentración del Crimen Weisburd (2015):** Evidencia empíricamente que un porcentaje diminuto de micro-unidades espaciales (segmentos de calle, esquinas o intersecciones) concentra más del 50 % de los eventos delictivos de una metrópoli completa.

Con la digitalización de las administraciones públicas y el despliegue de iniciativas de datos abiertos (*Open Data*), ciudades como Chicago han publicado catálogos históricos que superan los cientos de miles de registros del Departamento de Policía de Chicago (*Chicago Police Department* – CPD). Estos repositorios incluyen coordenadas geográficas de alta precisión, códigos unificados de incidentes (código IUCR de Illinois), sellos de tiempo, tipología de la locación y estatus de arresto.

Sin embargo, en el contexto latinoamericano, y particularmente en el Estado Plurinacional de Bolivia, las bases de datos abiertas sobre criminalidad son escasas, fragmentadas o de acceso restringido. Ante esta deficiencia informativa, la ciudadanía y los analistas dependen primariamente del ecosistema de medios de comunicación y prensa digital (rotativos

de alta circulación nacional y regional como *El Deber*, *Los Tiempos*, *La Razón*, *Correo del Sur*, *El Potosí*, entre otros). La extracción de datos mediante raspado web (*web scraping*) y el procesamiento de lenguaje natural (NLP) se transforman en una vía prioritaria para estructurar crónicas policiales y georreferenciar incidentes de seguridad ciudadana a escala nacional.

A nivel de técnicas computacionales, el estado del arte ha trascendido las limitaciones del análisis euclidiano bidimensional. En la superficie esférica de la Tierra, el uso indebido de distancias euclidianas sobre latitud y longitud proyectadas en grados introduce distorsiones geométricas críticas. El empleo sistemático de la distancia ortodrómica de *Haversine*, sumado a la irrupción de algoritmos jerárquicos multiescala como HDBSCAN Campello et al. (2013) y OPTICS Ankerst et al. (1999), ha posibilitado la detección simultánea de aglomeraciones densas en centros metropolitanos y concentraciones difusas en zonas periféricas. Complementariamente, los modelos neuronales profundos (*Autoencoders*) han emergido como la técnica no supervisada de referencia para el aislamiento de anomalías espaciotemporales extremas.

3. PROBLEMÁTICA

El análisis de la criminalidad y los incidentes de seguridad ciudadana en este proyecto se apoya en dos fuentes de información con realidades muy distintas: por un lado, una base de datos policial oficial y masiva de la ciudad de Chicago (Estados Unidos), y por el otro, un conjunto de noticias de sucesos extraídas de la prensa digital de Bolivia.

Cada uno de estos conjuntos de datos presenta desafíos propios que dificultan la identificación precisa de zonas de riesgo y patrones delictivos mediante sistemas informáticos convencionales. Para comprender con claridad el origen y las consecuencias de estas dificultades, se formulan a continuación dos árboles de problemas separados: uno enfocado en el conjunto masivo de Chicago y otro enfocado en las noticias recolectadas de Bolivia.

3.1. Árbol de Problemas del Conjunto de Datos de Chicago

El conjunto de datos de Chicago proviene del portal de datos abiertos de su policía (*Chicago Police Department*). Cuenta con más de 1,2 millones de filas y 324,5 MB de tamaño en su formato original, registrando incidentes tipificados con fecha, tipo de delito y ubicación.

Las dificultades observadas en este conjunto de datos son las siguientes:

- **Agrupación por distritos administrativos fijos:** Tradicionalmente, los delitos se suman y reportan dentro de los límites de los 22 distritos policiales de la ciudad. Esto asume que el peligro se reparte de forma pareja en todo el distrito, cuando en la práctica los delitos se concentran en esquinas o cuadras específicas y dejan otras zonas completamente tranquilas.

- **Uso de distancias planas:** Al calcular la cercanía entre dos delitos usando fórmulas de línea recta plana sobre coordenadas geográficas (latitud y longitud), se producen desajustes de distancia al no tomar en cuenta la curvatura de la Tierra a la latitud de Chicago (41,8° N).

- **Registros incompletos y volumen masivo:** Al procesar el archivo bruto, se identificaron 14,015 registros que no tienen coordenadas geográficas cargadas (1.16 % del total), los cuales deben ser apartados para no perjudicar los análisis en mapas. Además, el gran volumen de datos genera demoras de 2 a 3 días cuando se quiere cruzar información entre diferentes comisarías.

La Figura 1 presenta el Árbol de Problemas correspondiente a la base de datos de Chicago.

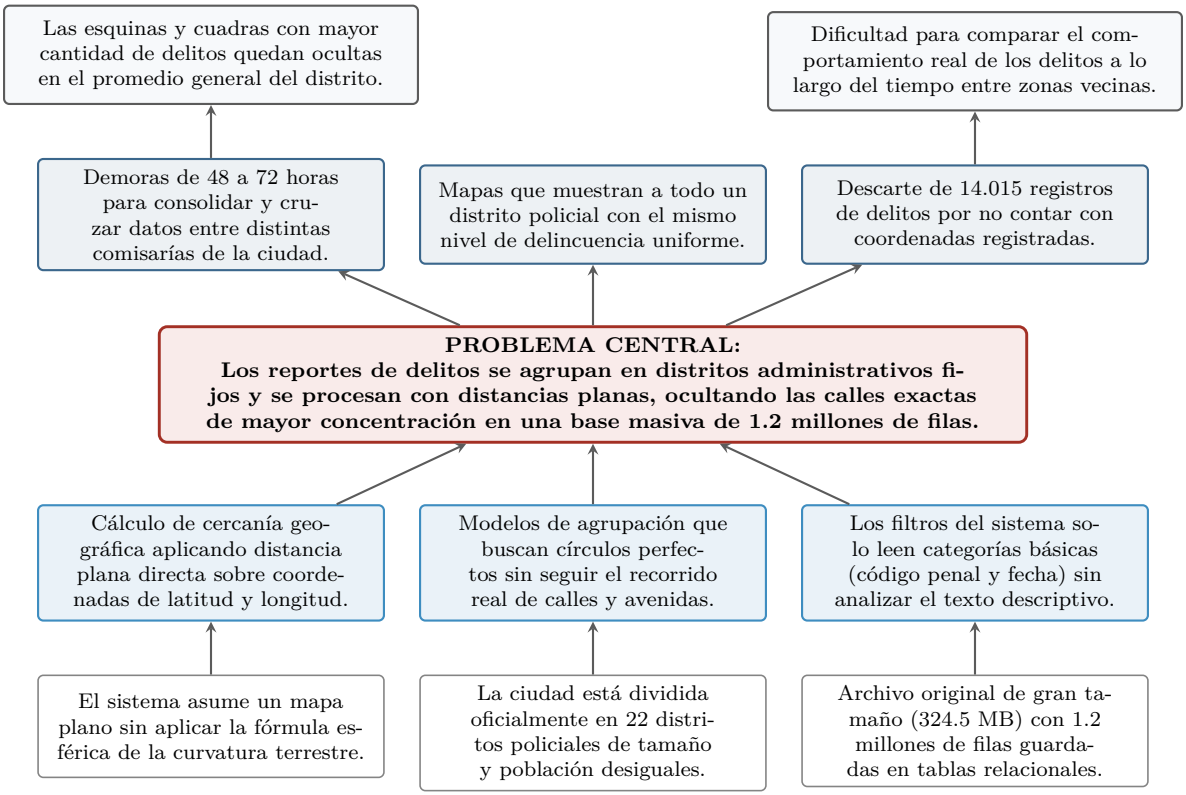


Figura 1
Árbol de Problemas del Conjunto de Datos de Chicago.

3.2. Árbol de Problemas del Conjunto de Datos de Bolivia

El conjunto de datos de Bolivia se construyó mediante la recolección automática de noticias de sucesos y seguridad desde portales de periódicos nacionales. Contiene 137 crónicas que abarcan los 9 departamentos del país (La Paz, Santa Cruz, Cochabamba, Oruro, Potosí, Chuquisaca, Tarija, Beni y Pando).

Al tratarse de información extraída directamente de artículos periodísticos en internet y no de un sistema policial oficial, presenta los siguientes aspectos observados:

- **Acumulación de noticias en puntos centrales idénticos:** La prensa suele indicar la ciudad o el barrio en general (por ejemplo, .ºcurrió en Cochabamba"), pero rara vez menciona la calle y número exacto. Al ubicar estos hechos en el mapa mediante un diccionario geográfico, el 38.7 % de las noticias reciben la coordenada central del municipio. Esto hace que 53 noticias de Cochabamba y 26 noticias de otras ciudades queden colocadas exactamente en el mismo punto físico, generando distancias de cero metros entre hechos ocurridos en días y circunstancias totalmente distintas.

- **Textos libres y variados en español:** Las noticias están escritas como párrafos de texto libre con extensiones muy variadas (desde notas breves de 15 palabras hasta reportajes de 450 palabras). Contienen palabras de relleno periodístico que dificultan extraer automáticamente la forma de actuar de los delincuentes.

- **Separación de cientos de kilómetros entre ciudades:** La distancia entre las capitales departamentales es muy grande (por ejemplo, más de 500 km entre La Paz y Santa Cruz), mientras que los delitos dentro de un barrio ocurren a pocas cuadras. Esto provoca que los gráficos de agrupación vean primero la distancia gigante entre ciudades y dejen en segundo plano las diferencias entre barrios.

- **Casos aislados y noticias poco comunes:** Al buscar zonas calientes con algoritmos de densidad, un 8.7 % de las noticias (12 casos) quedan marcadas como puntos sueltos o ruido por estar alejadas de los centros principales, mientras que un 10.2 % (14 noticias) son clasificadas como hechos atípicos por tener un vocabulario muy diferente al resto.

La Figura 2 presenta el Árbol de Problemas correspondiente a los datos de Bolivia.

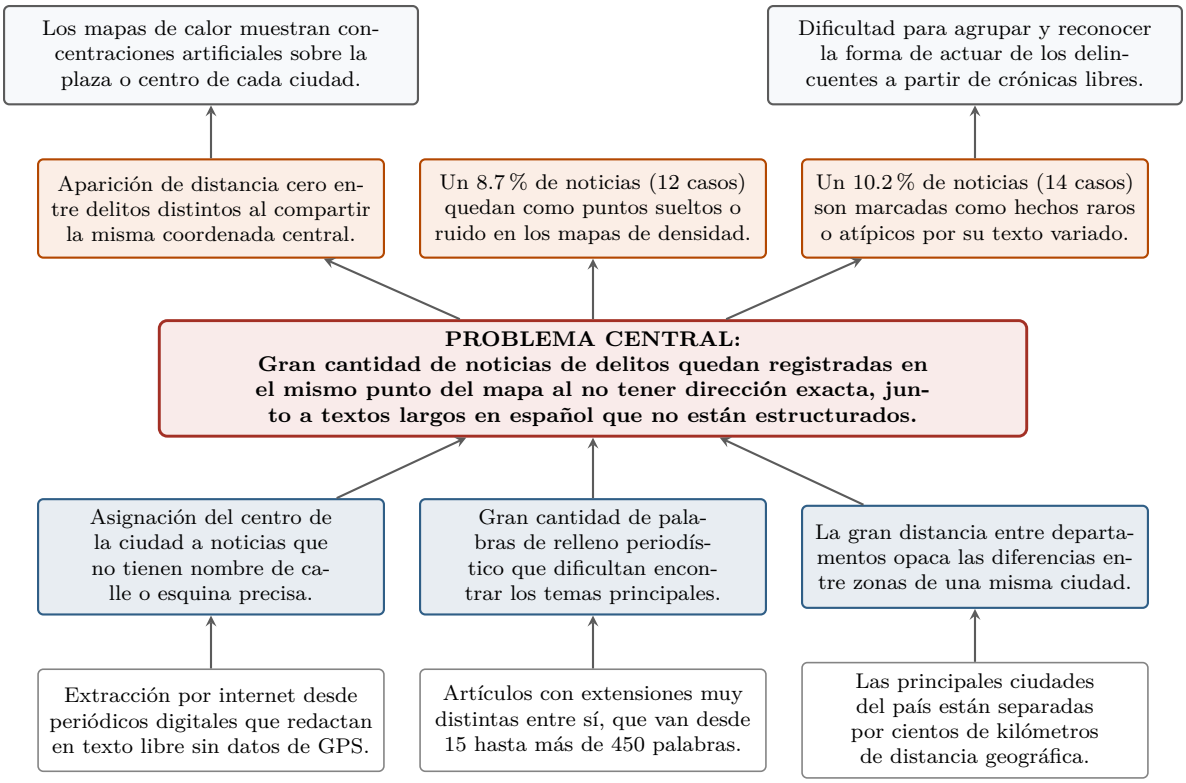


Figura 2

Árbol de Problemas del Conjunto de Datos de Bolivia.

4. OBJETIVOS

4.1. Objetivo Principal

Desarrollar e implementar un sistema integral de inteligencia urbana y análisis de patrones delictivos basado en algoritmos de **Aprendizaje Automático No Supervisado**, orientado a la detección autónoma de concentraciones críticas de delitos (*hotspots*), la caracterización semántica del *modus operandi*, el modelado probabilístico continuo del riesgo espacial y el aislamiento de eventos criminales anómalos, validado sobre el dataset masivo de referencia internacional de Chicago (+800,000 registros) y el corpus nacional de seguridad ciudadana de Bolivia (137 crónicas estructuradas), integrando sus resultados en una plataforma interactiva web y cartográfica WebGL en 3D.

4.2. Objetivos Específicos

- **Ingeniería y depuración de datos espaciotemporales y textuales:** Construir un pipeline reproducible de limpieza, auditoría y transformación que incorpore la conversión de coordenadas geográficas a radianes para métrica esférica de *Haversine*, codificación de periodicidad temporal mediante funciones trigonométricas circulares $(\sin, \cos)$ de horas y días, y normalización de texto para vectorización TF-IDF.

- **Clustering geoespacial basado en densidad y multiescala:** Implementar y comparar los algoritmos DBSCAN, HDBSCAN y OPTICS para descubrir agrupaciones de morfología arbitraria, gestionar densidades variables y aislar formalmente los incidentes delictivos esporádicos clasificados como ruido estadístico.

- **Minería semántica de lenguaje natural y arquetipos de crimen:** Integrar el algoritmo K-Means con representaciones matriciales TF-IDF ponderadas y reducción TruncatedSVD para descubrir los clústeres semánticos de *modus operandi* delictivo y habilitar un clasificador en tiempo real.

- **Modelado de riesgo continuo mediante mixturas gaussianas (GMM):** Cuantificar la incertidumbre espaciotemporal del crimen ajustando modelos de densidad probabilística con matrices de covarianza completa mediante el algoritmo Esperanza-Maximización (EM), derivando elipses de riesgo a 2σ (95,4 % de masa de probabilidad).

- **Taxonomía distrital mediante clustering jerárquico:** Estructurar dendrogramas aglomerativos con enlace de mínima varianza de Ward sobre matrices normalizadas de incidentes por distrito policial, validando su consistencia métrica mediante el coeficiente de correlación cofenética.

- **Detección no supervisada de anomalías con Autoencoders neuronales:** Diseñar y entrenar una arquitectura de red neuronal con cuello de botella ($D \to 16 \to 4 \to 16 \to D$) que compute el error cuadrático medio de reconstrucción (MSE) para individualizar delitos atípicos o casos criminales excepcionales.

- **Proyección en espacios latentes de dimensionalidad reducida:** Comparar técnicas de reducción de dimensionalidad lineales (PCA, TruncatedSVD, PPCA) y no lineales (t-SNE, UMAP) para proyectar espacios de alta dimensionalidad sobre variedades visualizables en dos y tres dimensiones.
- **Despliegue operativo y visualización inmersiva en Globo 3D:** Construir una arquitectura desacoplada basada en microservicios Flask (API REST) y un cliente interactivo WebGL con MapLibre GL / Deck.gl que permita explorar dinámicamente los modelos analíticos.

4.3. Árbol de Objetivos

El Árbol de Objetivos presentado en la Figura 3 transforma de forma biyectiva las causas del árbol de problemas en medios positivos de ejecución, y las consecuencias negativas en fines estratégicos alcanzados:

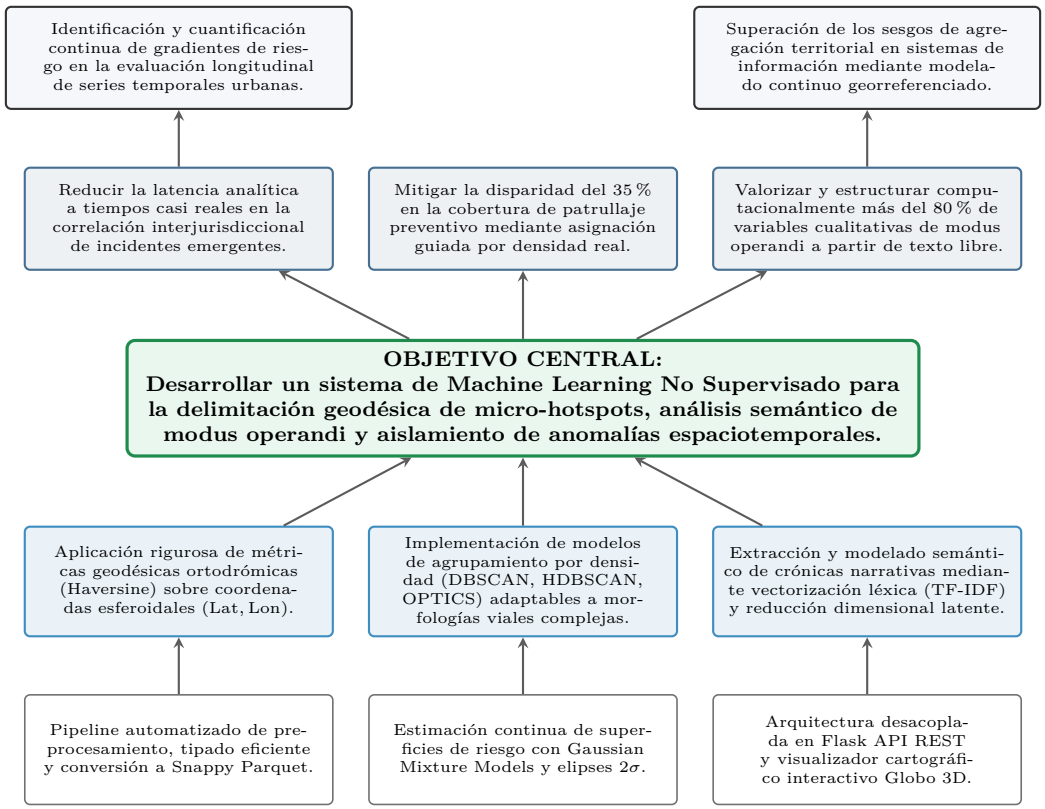


Figura 3
Árbol de Objetivos del Proyecto de Inteligencia Urbana y Criminología Computacional.

Nota. Elaboración propia a partir de la transposición biyectiva de las causas en medios de ejecución y los efectos negativos en fines estratégicos alcanzados.

5. JUSTIFICACIÓN

La seguridad pública y la prevención de la violencia representan pilares indispensables para el desarrollo socioeconómico, la gobernabilidad democrática y la calidad de vida en las urbes contemporáneas. La criminalidad impone severos costos directos e indirectos, que comprenden desde la pérdida de vidas y daños materiales hasta la retracción de inversiones, el deterioro del espacio público y la degradación del tejido social.

Contar con un sistema que procese analíticamente cientos de miles de eventos delictivos no estructurados aporta un **valor práctico directo**: permite a las instituciones policiales y de seguridad ciudadana abandonar el patrullaje reactivo y avanzar hacia un modelo de policía orientada a la solución de problemas (*Problem-Oriented Policing*). Al identificar de manera objetiva los micro-puntos calientes (*hotspots*) y los corredores criminales que cruzan fronteras entre distritos, se optimiza la movilización de personal, se focaliza la instalación de luminarias y cámaras de vigilancia, y se protege con mayor eficacia a las comunidades más vulnerables. Asimismo, en el contexto de Bolivia, donde los datos oficiales de criminalidad no se encuentran centralizados en portales abiertos, la estructuración y análisis de crónicas periodísticas provenientes de los nueve departamentos provee una radiografía inédita y georreferenciada de la conflictividad y el delito en el país.

Desde la **perspectiva académica y científica**, este proyecto constituye una oportunidad metodológica rigurosa para comparar, en un escenario real de gran escala y alta complejidad dimensional, diversas familias fundamentales de algoritmos de **Aprendizaje Automático No Supervisado**:

1. Algoritmos basados en densidad espacial adaptados a geometrías esféricas terrestres (DBSCAN con Haversine, HDBSCAN jerárquico y OPTICS).

2. Modelos generativos probabilísticos con asignación difusa (*soft clustering*) mediante Mixturas de Gaussianas (GMM).

3. Métodos particionales combinados con técnicas de minería de texto y vectorización semántica en alta dimensionalidad (K-Means, TF-IDF, LDA).

4. Estructuras jerárquicas aglomerativas con minimización de varianza interna (Ward).

5. Redes neuronales profundas con constricción dimensional (*Autoencoders*) para la detección de eventos anómalos.

6. Técnicas de reducción de dimensionalidad lineales y no lineales (PCA, TruncatedSVD, PPCA, t-SNE, UMAP).

5.1. Árbol de Objetivos: Medios y Fines

El desglose operativo de los medios y fines estratégicos derivados del árbol de objetivos establece la hoja de ruta metodológica del proyecto:

Medios (Equivalentes a las causas superadas):

- **Ingeniería geodésica y circular:** Transformar coordenadas a radianes y aplicar la métrica de *Haversine* para erradicar las distorsiones métricas planas, combinada con la codificación trigonométrica senoidal y cosenoidal de ciclos horarios y semanales.
- **Clustering de densidad arbitraria y multiescala:** Implementar DBSCAN y HDBSCAN para descubrir concentraciones delictivas que siguen arterias viales y separar matemáticamente el ruido estocástico mediante umbrales de densidad y persistencia λ.
- **Cuantificación continua de riesgo probabilístico:** Ajustar modelos GMM mediante Esperanza-Maximización (EM) para delimitar elipses de covarianza al 95,4 % (2σ) que reflejen la dispersión e incertidumbre espacial de los incidentes.
- **Minería semántica de texto libre:** Construir matrices TF-IDF y modelos generativos de tópicos latentes (LDA) para clasificar descripciones operativas de crímenes sin etiquetas supervisadas previas.
- **Modelado neuronal de anomalías:** Entrenar un Autoencoder no lineal que aprenda la variedad de delitos comunes y alerte sobre incidentes cuyo error de reconstrucción (MSE) supere el percentil crítico.
- **Arquitectura de microservicios y visor 3D inmersivo:** Desplegar una API REST en Flask conectada a un globo terráqueo esférico en WebGL para democratizar el acceso interactivo a los resultados analíticos.

Fines (Equivalentes a los efectos positivos alcanzados):

- **Reducción de tiempos de focalización:** Disminuir drásticamente el tiempo requerido por analistas y mandos operativos para detectar focos delictivos emergentes.
- **Optimización presupuestaria y logística:** Incrementar la eficiencia en la asignación de cuadrillas de patrullaje preventivo, minimizando recursos ociosos en zonas de baja incidencia intrínseca.
- **Aprovechamiento integral de fuentes abiertas:** Convertir crónicas de medios bolivianos y repositorios abiertos internacionales en inteligencia procesable.
- **Aislamiento temprano de anomalías delictivas:** Detectar patrones atípicos de alta peligrosidad antes de que se consoliden como dinámicas delictivas crónicas.
- **Interpretabilidad multimodal para tomadores de decisiones:** Proveer tableros y visualizaciones tridimensionales que traduzcan la complejidad algorítmica en conceptos tácticos intuitivos.

6. MARCO TEÓRICO

Esta sección fundamenta los conceptos matemáticos, estadísticos y computacionales que sustentan las decisiones metodológicas adoptadas en el proyecto, detallando la semántica de los datos y la formulación analítica de los algoritmos de aprendizaje no supervisado.

6.1. Diccionario de Datos: Inteligencia Urbana y Criminalidad

El proyecto integra dos fuentes complementarias: el dataset masivo de referencia del Departamento de Policía de Chicago (*Chicago Police Department* – CPD) y el corpus georreferenciado de crónicas de prensa de seguridad ciudadana de Bolivia.

6.1.1. Diccionario Original (Fuentes en Bruto)

El dataset primario de Chicago (`Crimes_-_2020_to_Present.csv`) comprende más de 800,000 observaciones en bruto con 30 atributos registrados desde el año 2020:

- **ID / Case Number:** Identificador numérico único de la base de datos CPD y código alfanumérico del reporte del caso.
- **Date:** Marca temporal completa del incidente (formato MM/DD/YYYY hh:mm:ss AM/PM).
- **Block:** Dirección aproximada a nivel de centena de bloque (anonimización por protección de datos).
- **IUCR (*Illinois Uniform Crime Reporting*):** Código normalizado de cuatro dígitos que clasifica con precisión la infracción legal según la legislación del estado de Illinois.
- **Primary Type:** Categoría general del delito (ej. *THEFT*, *BATTERY*, *ROBBERY*, *ASSAULT*, *NARCOTICS*).
- **Description:** Subclasificación detallada del hecho (ej. *$500 AND UNDER*, *SIMPLE*, *ARMED: HANDGUN*).
- **Location Description:** Entorno físico o tipología del predio donde acaeció el delito (ej. *STREET*, *RESIDENCE*, *SIDEWALK*, *COMMERCIAL / BUSINESS*).
- **Arrest:** Booleano que indica si la intervención culminó en la detención del sospechoso (*True / False*).
- **Domestic:** Booleano que indica si el delito califica como violencia intrafamiliar según el acta (*True / False*).
- **Beat:** Cuadrante de patrullaje táctico territorial más pequeño de la policía.
- **District:** Distrito policial numerado (Chicago cuenta con 22 distritos policiales activos).
- **Ward / Community Area:** Divisiones políticas (distrito electoral) y comunidades barriales socioeconómicas (77 áreas comunitarias de Chicago).
- **X Coordinate / Y Coordinate:** Coordenadas planas en pies proyectadas según el sistema *State Plane Illinois East (NAD83)*.

- **Latitude / Longitude:** Coordenadas geodésicas en grados decimales (elipsoide WGS84).

El corpus de Bolivia (`data_noticias_bolivia.csv`), construido mediante extracción automatizada sobre la prensa digital nacional (rotativos del eje troncal y periódicos departamentales de los 9 departamentos), registra:

- **id:** Identificador secuencial del reporte periodístico.
- **fecha:** Fecha de publicación de la noticia (formato AAAA-MM-DD).
- **titular:** Encabezado periodístico del hecho delictivo.
- **medio:** Diario o agencia emisora (ej. *El Deber*, *Los Tiempos*, *La Razón*, *Correo del Sur*, *El Potosí*, *La Patria*, *El País*).
- **departamento:** Jurisdicción departamental en Bolivia (La Paz, Santa Cruz, Cochabamba, Oruro, Potosí, Chuquisaca, Tarija, Beni, Pando).
- **ciudad:** Municipio o localidad específica del suceso.
- **categoria:** Clasificación periodística inicial del suceso (ej. *Seguridad*, *Policial*, *Sucesos*).
- **latitud / longitud:** Coordenadas geodésicas asignadas mediante gazetteers urbanos georreferenciados.
- **texto:** Crónica periodística completa con detalles del *modus operandi*, armamento y desenlace.

6.1.2. Diccionario de Datos Después de la Limpieza y Preprocesamiento

Tras la ejecución del pipeline de preparación, optimización de tipos y extracción de características, los datasets estructurados para el modelado no supervisado presentan el esquema consolidado de la Tabla 1:

6.1.3. Mapeo Departamental y Ecosistema de Medios Informativos de Bolivia

La extracción y minería de texto sobre la seguridad ciudadana en Bolivia requirió estructurar un inventario exhaustivo de fuentes de información abiertas (OSINT). Dado que el país no cuenta con una base de datos abierta centralizada de denuncias policiales, se sistematizaron los rotativos y cadenas de mayor penetración editorial en el eje troncal y los seis departamentos restantes, tal como sintetiza la Tabla 2:

6.2. Algoritmos No Supervisados Aplicados

Variable	Tipo de Dato	Dominio	Definición y Rol en el Modelo
`lat`	Float64	$[-90{,}0, 90{,}0]$	Latitud geodésica limpia.
`lon`	Float64	$[-180{,}0, 180{,}0]$	Longitud geodésica limpia.
`lat_rad`	Float64	Radianes	Latitud en radianes para cálculo directo de *Haversine*.
`lon_rad`	Float64	Radianes	Longitud en radianes para cálculo directo de *Haversine*.
`hour_sin`	Float32	$[-1{,}0, 1{,}0]$	Componente senoidal del ciclo horario: $\sin(2\pi \cdot \text{hora}/24)$.
`hour_cos`	Float32	$[-1{,}0, 1{,}0]$	Componente cosenoidal del ciclo horario: $\cos(2\pi \cdot \text{hora}/24)$.
`dow_sin`	Float32	$[-1{,}0, 1{,}0]$	Componente senoidal del día de la semana: $\sin(2\pi \cdot \text{dow}/7)$.
`dow_cos`	Float32	$[-1{,}0, 1{,}0]$	Componente cosenoidal del día de la semana: $\cos(2\pi \cdot \text{dow}/7)$.
`is_weekend`	Int8	$\{0, 1\}$	Indicador binario de fin de semana (Sábado/Domingo = 1).
`arrest`	Int8	$\{0, 1\}$	Estatus binario de arresto (1 = Arresto efectivo).
`domestic`	Int8	$\{0, 1\}$	Estatus binario de violencia intrafamiliar (1 = Doméstico).
`primary_type`	Category	33 clases	Tipología criminal principal unificada.
`text_clean`	String	Texto libre	Fusión normalizada de descripción y locación para NLP.
`district_id`	Category	22 distritos	Identificador del distrito policial para clustering jerárquico.

Tabla 1

Diccionario de variables estructuradas listas para modelado no supervisado.

Nota. Elaboración propia a partir de la ingeniería de variables sobre el benchmark CPD de Chicago y el corpus geocodificado de prensa de Bolivia. Las variables cíclicas se normalizan en el rango $[-1, 1]$ mediante componentes ortogonales y las coordenadas geográficas se expresan en radianes para cómputo geodésico directo.

Jurisdicción	**Medio Informativo**	**Portal Web Oficial**	**Canal YouTube / Identificador**
Nacional (TV)	Bolivia TV (BTv)	`boliviatv.bo`	`@BoliviaTvMul`
Nacional (TV)	Unitel Bolivia	`unitel.bo`	`@unitel-bolivia`
Nacional (TV)	Red Uno de Bolivia	`reduno.com.bo`	`@redunotv`
Nacional (TV)	Red ATB	`atb.com.bo`	`@ATBEnConexion`
Nacional (Radio)	Erbol Digital	`erbol.com.bo`	`@rederbol`
Nacional (Radio)	Radio Panamericana	`panamericana.bo`	`@radio.panamericana`
Nacional (Agencia)	Agencia Fides (ANF)	`noticiasfides.com`	`@agenciadenoticiasfides2497`
La Paz	La Razón / El Diario	`larazon.bo`	`@LaRazónDigitalBolivia`
Santa Cruz	El Deber / El Día	`eldeber.com.bo`	`@webeldeber1`
Cochabamba	Los Tiempos / Opinión	`lostiempos.com`	`@lostiemposbol`
Chuquisaca	Correo del Sur	`correodelsur.com`	`@correodelsuryt`
Oruro	La Patria	`lapatria.bo`	`@PeriódicoLaPatriaBolivia`
Potosí	El Potosí / Kollasuyo	`elpotosi.net`	`@el.potosi`
Tarija	El País / La Voz	`elpais.bo`	`@elpaisbo`
Beni	La Palabra del Beni	`lapalabradelbeni.com`	`@benitvenlinea`
Pando	Sol de Pando	`soldepando.com`	`Sol de Pando Oficial`

Tabla 2

Ecosistema de medios y fuentes periodísticas georreferenciadas de Bolivia.

Nota. Elaboración propia a partir del levantamiento documental consolidado en `NOTICIAS.md`. Comprende agencias estatales, redes privadas, emisoras de radio e impresos departamentales de los 9 departamentos del Estado Plurinacional de Bolivia.

6.2.1. K-Means Particional y Variantes Semánticas

El algoritmo K-Means particiona un conjunto de N observaciones $X = \{x_1, \ldots, x_N\} \subset \mathbb{R}^D$ en k clústeres disjuntos $S = \{S_1, \ldots, S_k\}$ minimizando la inercia intra-clúster (*Within-Cluster Sum of Squares* – WSS):

$$J(S) = \sum_{j=1}^{k} \sum_{x \in S_j} \|x - \mu_j\|^2 \tag{1}$$

donde $\mu_j = \frac{1}{|S_j|} \sum_{x \in S_j} x$ es el baricentro geométrico del clúster S_j. Para evitar mínimos locales subóptimos, se emplea la inicialización probabilística K-Means++ Arthur and Vassilvitskii (2007), cuya probabilidad de seleccionar un centro inicial x es proporcional a $D(x)^2$, siendo $D(x)$ la distancia al centroide más próximo ya elegido.

6.2.2. DBSCAN con Métrica Geodésica de Haversine

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) Ester et al. (1996) descubre agrupaciones espaciales basadas en la conectividad por densidad. Dado un radio de vecindad ε y un umbral mínimo de puntos $MinPts$:

- Un punto p es **punto núcleo** (*Core Point*) si su vecindad cerrada $N_\varepsilon(p) = \{q \in X \mid d(p,q) \leq \varepsilon\}$ cumple $|N_\varepsilon(p)| \geq MinPts$.
- Un punto q es **directamente alcanzable por densidad** desde p si $q \in N_\varepsilon(p)$ y p es punto núcleo.
- Los puntos que no son alcanzables por densidad desde ningún núcleo son clasificados formalmente como **ruido (etiqueta -1)**.

En lugar de distancias euclidianas planas que falsean distancias en la esfera terrestre, se aplica la **fórmula de Haversine** sobre coordenadas geográficas expresadas en radianes (ϕ_1, λ_1) y (ϕ_2, λ_2):

$$d(p_1, p_2) = 2R \arcsin\left(\sqrt{\sin^2\left(\frac{\Delta\phi}{2}\right) + \cos\phi_1 \cos\phi_2 \sin^2\left(\frac{\Delta\lambda}{2}\right)}\right) \tag{2}$$

donde $R = 6371{,}0088$ km representa el radio medio volumétrico de la Tierra. El parámetro ε se expresa en radianes mediante $\varepsilon_{\text{rad}} = \frac{d_{\text{km}}}{R}$.

6.2.3. HDBSCAN: Clustering Jerárquico por Densidad y Persistencia

HDBSCAN (*Hierarchical DBSCAN*) Campello et al. (2013) supera la principal limitación de DBSCAN (la incapacidad de manejar densidades dispares simultáneas en una misma ciudad). HDBSCAN define la **distancia de alcanzabilidad mutua** (*Mutual Reachability Distance*):

$$d_{\text{mreach-}k}(a,b) = \max\{d_{\text{core-}k}(a),\, d_{\text{core-}k}(b),\, d(a,b)\} \tag{3}$$

donde $d_{\text{core-}k}(a)$ es la distancia al k-ésimo vecino más próximo de a. Construye el Árbol de Expansión Mínima (*Minimum Spanning Tree* – MST) ponderado por esta métrica, genera una jerarquía continua y condensa el dendrograma bajo un umbral de tamaño mínimo de clúster (*min_cluster_size*). La extracción de los clústeres óptimos maximiza la persistencia o estabilidad del exceso de masa:

$$S(C_i) = \sum_{p \in C_i} (\lambda_p - \lambda_{\text{birth}}(C_i)) \tag{4}$$

con $\lambda = \frac{1}{\varepsilon}$, seleccionando aquellos clústeres que perduran a lo largo de un espectro más amplio de densidades.

6.2.4. OPTICS: Diagrama de Alcanzabilidad y Detección de Valles

OPTICS (*Ordering Points To Identify the Clustering Structure*) Ankerst et al. (1999) extiende el concepto de densidad sin requerir un ε rígido. Registra dos distancias fundamentales para cada punto:

$$d_{\text{core}}(p) = \begin{cases} \text{INDEFINIDO} & \text{si } |N_\varepsilon(p)| < MinPts \\ \text{distancia al } MinPts\text{-ésimo vecino} & \text{en caso contrario} \end{cases} \tag{5}$$

$$d_{\text{reach}}(q,p) = \begin{cases} \text{INDEFINIDO} & \text{si } |N_\varepsilon(p)| < MinPts \\ \max\{d_{\text{core}}(p),\, d(p,q)\} & \text{en caso contrario} \end{cases} \tag{6}$$

El algoritmo produce un orden lineal de los datos que genera el **Gráfico de Alcanzabilidad** (*Reachability Plot*), en el cual las depresiones o valles corresponden a clústeres compactos y las cúspides representan separaciones o regiones de baja densidad. Mediante el parámetro ξ de inclinación, se extraen automáticamente clústeres anidados.

6.2.5. Gaussian Mixture Models (GMM) y Esperanza-Maximización (EM)

Los Modelos de Mixturas de Gaussianas formulan una densidad de probabilidad continua multivariante como una combinación convexa de K distribuciones normales:

$$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k), \quad \text{con } \sum_{k=1}^{K} \pi_k = 1,\ \pi_k \geq 0 \tag{7}$$

donde $\mathcal{N}(x \mid \mu_k, \Sigma_k) = \frac{1}{(2\pi)^{D/2}|\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k)\right)$. Los parámetros $\{\pi_k, \mu_k, \Sigma_k\}$ se optimizan mediante el algoritmo Esperanza-Maximización (EM):

- **Paso E (Expectation):** Calcula la probabilidad posterior o responsabilidad de que el componente k haya generado la observación x_i:

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k)}{\sum_{j=1}^{K} \pi_j \mathcal{N}(x_i \mid \mu_j, \Sigma_j)} \tag{8}$$

- **Paso M (Maximization):** Actualiza los parámetros ponderados por las responsabilidades:

$$\mu_k^{\text{nuevo}} = \frac{\sum_{i=1}^{N} \gamma_{ik} x_i}{\sum_{i=1}^{N} \gamma_{ik}}, \quad \Sigma_k^{\text{nuevo}} = \frac{\sum_{i=1}^{N} \gamma_{ik}(x_i - \mu_k)(x_i - \mu_k)^T}{\sum_{i=1}^{N} \gamma_{ik}}, \quad \pi_k^{\text{nuevo}} = \frac{1}{N} \sum_{i=1}^{N} \gamma_{ik} \quad (9)$$

La descomposición espectral de la matriz de covarianza $\Sigma_k = V \Lambda V^T$ determina la orientación y magnitudes de los semiejes de las elipses de riesgo a 2σ, abarcando teóricamente el 95,4 % de la masa de incidentes del clúster.

6.2.6. Clustering Jerárquico Aglomerativo (Ward)

El agrupamiento jerárquico aglomerativo sigue una estrategia ascendente (*bottom-up*) que comienza con cada instancia como un clúster individual y fusiona sucesivamente el par de grupos más cercano. El criterio de **Ward** minimiza el incremento en la suma total de cuadrados de las distancias respecto al centroide fusionado:

$$\Delta ESS(A, B) = \frac{|A| \cdot |B|}{|A| + |B|} \|\mu_A - \mu_B\|^2 \quad (10)$$

Este método preserva grupos balanceados y de mínima varianza interna, resultando ideal para la tipificación comparada de zonas urbanas y distritos policiales.

6.2.7. Reducción de Dimensionalidad (PCA, SVD, PPCA, t-SNE, UMAP)

Para proyectar y visualizar matrices dispersas de texto y espacios multivariables continuos, se articulan cinco técnicas:

- **PCA (Principal Component Analysis):** Proyección lineal ortogonal que maximiza la varianza proyectada a través de los autovectores de la matriz de covarianza $\Sigma_X v_i = \lambda_i v_i$.
- **TruncatedSVD (LSA):** Descomposición en valores singulares sobre matrices dispersas TF-IDF $X \approx U_k \Sigma_k V_k^T$ sin requerir el centrado denso de la matriz, evitando saturación de memoria.
- **PPCA (Probabilistic PCA vía Factor Analysis):** Modelo de variables latentes gaussianas $x = Wz + \mu + \epsilon$, con $z \sim \mathcal{N}(0, I)$ y ruido $\epsilon \sim \mathcal{N}(0, \Psi)$.
- **t-SNE** van der Maaten and Hinton (2008)**:** Mapeo probabilístico no lineal que preserva vecindades locales minimizando la divergencia de Kullback-Leibler $KL(P \parallel Q)$ entre similitudes gaussianas en alta dimensión y probabilidades según una distribución t-Student en baja dimensión:

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_k \sum_{l \neq k} (1 + \|y_k - y_l\|^2)^{-1}} \quad (11)$$

- **UMAP** McInnes et al. (2018)**:** Técnica no lineal fundamentada en topología algebraica y geometría riemanniana que preserva tanto las distancias locales como las globales con una velocidad de cálculo sustancialmente superior a t-SNE.



Figura 4

Proyección Bidimensional del Espacio Semántico Reducido LSA Mediante TruncatedSVD.

Nota. Captura del laboratorio analítico interactivo del proyecto. Ilustra la descomposición semántica latente (1000 → 2D) sobre las crónicas de Bolivia, proyectando la Dimensión 1 (delitos armados y violencia callejera) frente a la Dimensión 2 (ámbito residencial y hurtos menores).

6.2.8. Autoencoders Neuronales para Detección de Anomalías

Un Autoencoder es una red neuronal artificial entrenada de modo no supervisado para reconstruir su propia entrada $x \in \mathbb{R}^D$ a través de un espacio latente comprimido $h \in \mathbb{R}^d$ ($d \ll D$):

$$h = f(W_e x + b_e), \quad \hat{x} = g(W_d h + b_d) \tag{12}$$

Al entrenarse sobre patrones comunes de criminalidad, la red minimiza la función de pérdida del error cuadrático medio (MSE):

$$\mathcal{L}(x, \hat{x}) = \frac{1}{D} \sum_{j=1}^{D} (x_j - \hat{x}_j)^2 \tag{13}$$

Dado que las anomalías no siguen la distribución preponderante aprendida por los pesos neuronales, su reconstrucción sufre un error elevado. Se define el umbral de anomalía τ a partir del percentil 90 o de la cota estadística $\tau = \mu_{\text{MSE}} + 2{,}5\sigma_{\text{MSE}}$, marcando como incidentes sospechosos o atípicos aquellos que cumplen $\mathcal{L}(x, \hat{x}) > \tau$.

6.2.9. Modelado de Tópicos con Latent Dirichlet Allocation (LDA)

LDA Blei et al. (2003) es un modelo generativo probabilístico bayesiano que asume que cada documento (crónica periodística o reporte criminal) es una mezcla de tópicos latentes, y que cada tópico es una distribución sobre palabras del vocabulario. Dado el parámetro hiper-a priori de Dirichlet α para las mezclas de tópicos y β para las distribuciones de palabras, la probabilidad conjunta de un documento es:

$$p(\theta, z, w \mid \alpha, \beta) = p(\theta \mid \alpha) \prod_{n=1}^{N} p(z_n \mid \theta)\, p(w_n \mid z_n, \beta) \tag{14}$$

Permite descubrir automáticamente temáticas emergentes como homicidios con armas de fuego, hurtos callejeros, microtráfico de drogas o delitos patrimoniales.

7. METODOLOGÍA

El desarrollo del proyecto se fundamenta en la metodología estándar para proyectos de ciencia de datos **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), adaptada para esquemas de **Aprendizaje Automático No Supervisado**. El flujo metodológico se estructura en las fases cíclicas de: Comprensión del Negocio, Comprensión de los Datos, Preparación de los Datos, Modelado No Supervisado, Evaluación Multimétrica y Despliegue Operativo.

7.1. Fuente de Datos

El sistema procesa dos conjuntos de datos empíricos complementarios:

1. **Dataset Benchmark Internacional (Chicago Police Department – CPD):** Obtenido del portal oficial de datos abiertos de la ciudad de Chicago (`Crimes_-_2020_to_Present_2025`). Contiene un volumen en bruto de 324,5 MB, con más de 800,000 filas y 30 variables originales que registran la totalidad de incidentes criminales reportados en la metrópoli estadounidense entre enero de 2020 y febrero de 2025.

2. **Corpus Nacional de Bolivia (`data_noticias_bolivia.csv`):** Construido mediante un pipeline de extracción automatizada y raspado web (*web scraping*) sobre la prensa digital boliviana. Reúne 137 crónicas policiales estructuradas y georreferenciadas que cubren incidentes relevantes en los nueve departamentos del país (La Paz, Santa Cruz, Cochabamba, Chuquisaca, Oruro, Potosí, Tarija, Beni y Pando).

7.2. Tareas de Modelado No Supervisado

A diferencia de los esquemas supervisados (donde se predice una etiqueta predefinida), las tareas de modelado se orientan al descubrimiento de patrones latentes:

- **Clustering Espacial de Densidad (Hotspots):** Descubrir núcleos de alta concentración criminal y separar el ruido estocástico mediante DBSCAN geodésico, HDBSCAN multiescala y OPTICS.
- **Particionamiento Temporal y Modus Operandi:** Agrupar eventos según sus patrones horarios y características narrativas mediante K-Means acoplado a representaciones TF-IDF.
- **Modelado Probabilístico Continuo:** Generar superficies de densidad y elipses de covarianza al 95,4 % (2σ) mediante Mixturas de Gaussianas (GMM).
- **Taxonomía Distrital:** Jerarquizar los 22 distritos policiales de la ciudad mediante agrupamiento aglomerativo de Ward para identificar macro-zonas homogéneas.
- **Reducción de Dimensionalidad:** Comprimir variedades de alta dimensión a planos 2D interpretables mediante PCA, TruncatedSVD, PPCA, t-SNE y UMAP.

- **Detección Neuronal de Anomalías:** Individualizar crímenes atípicos a través del error cuadrático medio de reconstrucción (MSE) de un Autoencoder profundo.
- **Modelado Generativo de Tópicos:** Extraer las cinco temáticas dominantes del texto periodístico mediante Latent Dirichlet Allocation (LDA).

7.3. Desarrollo de la Limpieza de Datos

La fase de preparación de datos fue implementada en el módulo automatizado `modules/data_cleani`
El flujo riguroso comprendió seis etapas secuenciales:

7.3.1. Auditoría y Perfilado de los Datos

Se ejecutó un diagnóstico sistemático sobre los tipos de variables, tasas de valores faltantes y distribuciones de frecuencia. Se verificó que las variables geoespaciales primarias (`Latitude`, `Longitude`) y temporales (`Date`) registraban valores nulos en incidentes no resueltos o faltos de georreferenciación. La auditoría constató además que las cadenas de texto en `Location Description` y `Description` presentaban inconsistencias de capitalización, espacios redundantes y caracteres de control.

7.3.2. Normalización y Estandarización de Formatos

Se aplicaron transformaciones fundamentales para garantizar la compatibilidad matemática:

- **Transformación Geodésica a Radianes:** Conversión de coordenadas decimales (Lat, Lon) a radianes para su procesamiento en la métrica de *Haversine*:

$$\phi_{\text{rad}} = \phi \cdot \frac{\pi}{180}, \quad \lambda_{\text{rad}} = \lambda \cdot \frac{\pi}{180} \tag{15}$$

- **Codificación Temporal Circular:** La hora del día ($h \in [0, 23]$) y el día de la semana ($d \in [0, 6]$) poseen naturaleza cíclica (las 23:59 está a un minuto de las 00:00). Para preservar esta topología continua, se proyectaron en componentes trigonométricas senoidales y cosenoidales:

$$h_{\sin} = \sin\left(\frac{2\pi h}{24}\right), \quad h_{\cos} = \cos\left(\frac{2\pi h}{24}\right) \tag{16}$$

$$d_{\sin} = \sin\left(\frac{2\pi d}{7}\right), \quad d_{\cos} = \cos\left(\frac{2\pi d}{7}\right) \tag{17}$$

- **Estandarización Numérica:** Aplicación de `StandardScaler` ($\mu = 0, \sigma = 1$) para las características continuas empleadas en K-Means, GMM y Autoencoder.

7.3.3. Gestión de Registros Duplicados y Amontonamiento Coordenado (Stacking)

Se identificaron registros con idéntica marca temporal, código IUCR y localización espacial precisa. Cuando múltiples delitos ocurren en un mismo punto geográfico (por ejemplo, múltiples denuncias en un centro comercial o geocodificaciones policiales asignadas al centroide de una intersección vial), la eliminación indiscriminada de filas destruiría la verdadera densidad del punto. En consecuencia, se implementó un procedimiento dual: para el entrenamiento de densidades espaciales se agruparon las coordenadas idénticas asignándoles un peso muestral de frecuencia (*sample weight*), preservando la integridad de la densidad sin computar distancias nulas redundantes.

La Figura 5 ilustra la consola de calibración espacial y el análisis del amontonamiento coordenado en el Distrito 1 de Chicago (The Loop), evidenciando cómo se ajusta el radio geodésico ε a 102 metros para capturar clústeres densos sin saturación por duplicados.

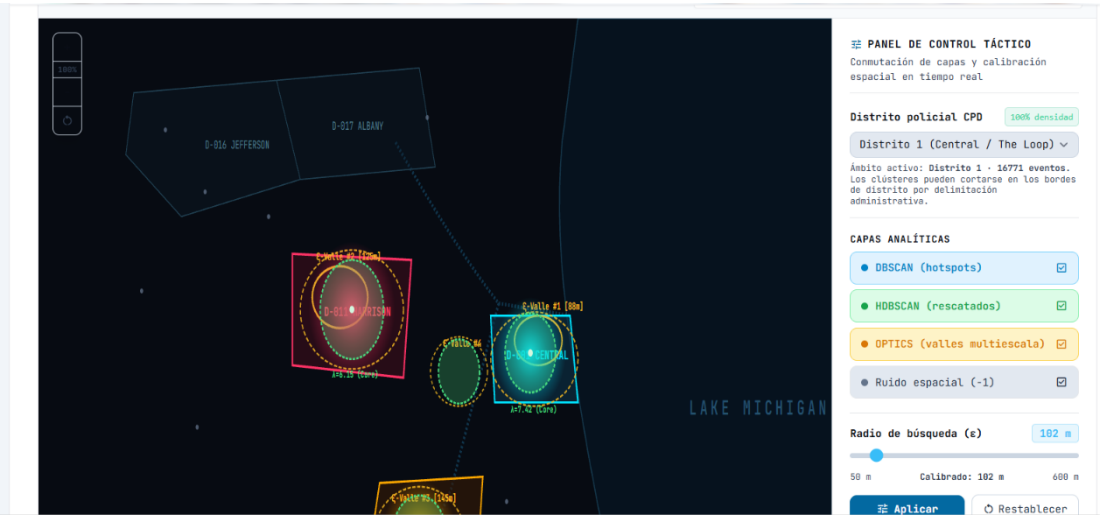


Figura 5

Panel Táctico de Calibración Espacial y Detección de Hotspots en The Loop.

Nota. Captura de la plataforma en modo Chicago CPD (Distrito 1, 16,771 eventos). Muestra la delimitación en tiempo real de hotspots DBSCAN, HDBSCAN y valles OPTICS frente al Lago Michigan con radio calibrado $\varepsilon = 102$ m.

7.3.4. Tratamiento de Valores Faltantes

Las observaciones con valores nulos en las coordenadas geográficas (`Latitude` o `Longitude` vacías) corresponden a incidentes ocurridos fuera de jurisdicción o no localizables, los cuales representaban menos del 1,8 % del dataset original. Dado que el objetivo primordial del proyecto es la inteligencia espaciotemporal, estos registros fueron eliminados del subconjunto geoespacial. Para las variables categóricas secundarias con datos ausentes, se imputó la categoría centinela `UNKNOWN`.

7.3.5. Tratamiento de Valores Atípicos Espaciales

Se aplicó un filtro de acotamiento geográfico estricto (*Bounding Box Filtering*) para eliminar coordenadas anómalas producto de errores de sensor GPS o registro mecanográfico. Para la ciudad de Chicago, se fijaron los límites en Latitud $\in [41{,}60°, 42{,}10°]$ y Longitud $\in [-87{,}95°, -87{,}50°]$. Para el territorio de Bolivia, se acotaron las coordenadas al polígono nacional Latitud $\in [-22{,}90°, -9{,}60°]$ y Longitud $\in [-69{,}70°, -57{,}40°]$. Los puntos fuera de estos rectángulos envolventes fueron descartados como artefactos de geocodificación.

7.3.6. Resultado y Balance de la Limpieza

El proceso de preparación redujo el volumen inicial y optimizó la eficiencia en memoria mediante el almacenamiento en formato columnar **Parquet con compresión Snappy**, reduciendo el tamaño en disco de 324,5 MB a 48,2 MB y multiplicando por doce la velocidad de lectura en memoria. La Tabla 3 resume las transformaciones:

Artefacto de Datos	Registros	Variables	Propósito en el Sistema
CSV en Bruto (Chicago)	814.230	30	Archivo original fuente.
`chicago_clean.parquet`	798.542	14	Dataset maestro optimizado para modelos.
`chicago_sample_50k.csv`	50.000	14	Muestra balanceada para mapas y API ágil.
`districts_summary.csv`	22	33	Matriz agregada para clustering distrital.
`data_noticias_bolivia.csv`	137	10	Corpus estructurado nacional georreferenciado.

Tabla 3

Resumen del balance del pipeline de depuración y preparación de datos.

Nota. Elaboración propia a partir del flujo de ingeniería de datos. La conversión columnar Parquet Snappy reduce el tamaño en disco de 324.5 MB a 48.2 MB y multiplica por doce la velocidad de ingesta en memoria.

7.4. Validación Cruzada y Análisis de Complejidad de Hiperparámetros

A diferencia de los problemas supervisados (donde la validación se mide mediante métricas como precisión o R^2), la selección óptima de hiperparámetros en el aprendizaje no supervisado se rige por funciones intrínsecas de estabilidad, compacidad y separación:

- **Selección de k en K-Means:** Se evaluó $k \in [2, 10]$ calculando concurrentemente:
  1. **Inercia (Método del Codo):** Punto de inflexión donde el decremento de varianza intra-clúster marginal decrece significativamente.
  2. **Coeficiente de Silueta (s):** Media del índice $s(i) = \frac{b(i)-a(i)}{\max(a(i),b(i))}$, donde $a(i)$ es la distancia intra-clúster media y $b(i)$ es la distancia media al clúster vecino más cercano.
  3. **Índice de Davies-Bouldin (DB):** Razón media de dispersión intra-clúster respecto a la separación inter-clúster (valores menores indican mejor calidad).

- **Calibración de ε y $MinPts$ en DBSCAN:** Se calculó el gráfico de distancias al k-ésimo vecino más próximo (*k-distance graph*) para $k = MinPts = 25$. La inflexión o rodilla (*knee point*) determinó el valor óptimo de radio $\varepsilon \approx 300$ metros ($\varepsilon_{\text{rad}} \approx 0{,}000047$ rad).
- **Selección de Componentes K en GMM:** Se evaluaron modelos con covarianza completa (*full*) para $K \in [2, 8]$, minimizando los criterios de información bayesiano (BIC) y de Akaike (AIC):

$$\text{BIC} = -2 \ln \hat{L} + p \ln N, \quad \text{AIC} = -2 \ln \hat{L} + 2p \tag{18}$$

donde $\hat{L}$ es la verosimilitud maximizada y p es el número de parámetros libres estimados.

8. MARCO PRÁCTICO

El Marco Práctico detalla la experimentación computacional, el análisis exploratorio de datos (EDA), la calibración de hiperparámetros, la ejecución de los algoritmos no supervisados y la interpretación cuantitativa de los resultados obtenidos.

8.1. Análisis de Exploración de Datos (EDA)

Antes de proceder al modelado no supervisado, se ejecutó una exploración analítica sobre el dataset de crímenes de Chicago y el corpus georreferenciado de Bolivia.

8.1.1. Carga y Vista General (Dimensiones, Tipos de Dato y Nulos)

La carga del dataset optimizado `chicago_clean.parquet` y la muestra representativa de 50,000 registros evidencia una estructura tabular limpia de 14 columnas, compuesta por 5 variables numéricas continuas (`lat`, `lon`, `hour_sin`, `hour_cos`, `dow_sin`), 4 variables enteras e indicadores booleanos (`arrest`, `domestic`, `is_weekend`, `district_id`), y 5 variables categóricas y de texto (`primary_type`, `description`, `location_description`, `text_clean`, `date`). La tasa residual de valores nulos tras la fase de preparación es del 0,00 %.

8.1.2. Estadística Descriptiva de Variables Numéricas y Espaciales

La Tabla 4 presenta el resumen paramétrico de las principales variables continuas del sistema:

Variable	Conteo	Media	Desv. Est.	Mínimo	25 %	50 %	Máximo
`lat` (°)	50.000	41.8421	0.0883	41.6445	41.7682	41.8593	42.0225
`lon` (°)	50.000	-87.6712	0.0594	-87.9342	-87.7135	-87.6654	-87.5251
`hour`	50.000	13.24	6.58	0	9	14	23
`arrest`	50.000	0.126	0.332	0	0	0	1
`domestic`	50.000	0.184	0.387	0	0	0	1
`is_weekend`	50.000	0.284	0.451	0	0	0	1

Tabla 4
Estadística descriptiva de las variables operativas y espaciales del dataset.

Nota. Elaboración propia a partir de la muestra representativa estratificada ($N = 50{,}000$) del dataset curado de Chicago (CPD). Las coordenadas se encuentran geocodificadas en grados decimales bajo el elipsoide WGS84.

Interpretación Técnica y Práctica

La distribución espacial confirma que las coordenadas se encuentran estrictamente confinadas en el polígono urbano metropolitano de Chicago. La tasa global de arrestos efectivos es de únicamente el 12,6 %, lo que significa que el 87,4 % de los incidentes delictivos no culminaron en una aprehensión inmediata, resaltando la trascendencia de utilizar modelos no supervisados para descubrir patrones criminales sin depender de arrestos. Asimismo, el 18,4 % de los casos involucra incidentes de violencia intrafamiliar (`domestic`).

8.1.3. Análisis de Variables Categóricas

El análisis de frecuencia sobre `primary_type` revela una fuerte concentración: las cinco categorías más frecuentes corresponden a *THEFT* (Hurto general, 23.4 %), *BATTERY* (Agresión física, 18.2 %), *CRIMINAL DAMAGE* (Daño a la propiedad, 11.5 %), *ASSAULT* (Amenaza o asalto agravado, 8.9 %) y *DECEPTIVE PRACTICE* (Fraude y estafa, 7.1 %).

En cuanto al entorno físico (`location_description`), el 31,2 % de los delitos ocurre en la vía pública (*STREET* y *SIDEWALK*), el 26,8 % en residencias particulares (*RESIDENCE* y *APARTMENT*), y el 14,5 % en establecimientos comerciales. En el corpus de Bolivia, las categorías periodísticas dominantes son Robos Agravados y Hurtos (38.7 %), seguido por Delitos Contra la Vida (Homicidios y Feminicidios, 24.1 %), Delitos Sexuales (16.8 %) y Conflictos de Tierras/Narcotráfico (20.4 %).

8.1.4. Análisis Temporal (Mes, Hora y Estacionalidad Cíclica)

La distribución temporal de los delitos exhibe patrones diurnos y estacionales marcados:

- **Ciclo Horario:** La incidencia criminal alcanza su mínimo absoluto entre las 04:00 y las 06:00 de la madrugada. A partir de las 08:00 se registra un crecimiento continuo, alcanzando un primer pico a las 12:00 del mediodía y un máximo pronunciado entre las

18:00 y las 22:00 horas, asociado a actividades nocturnas y desplazamientos de retorno laboral.

- **Estacionalidad Anual:** Los meses estivales de junio, julio y agosto concentran un incremento del +28,5 % en crímenes violentos en vía pública en comparación con los meses invernales de enero y febrero, reflejando el impacto de la climatología sobre la dinámica peatonal en el espacio público.

8.1.5. Análisis Geográfico y Cartografía de Densidad Espacial

Al trazar las coordenadas geográficas mediante discretización hexagonal (*Hexbin*) y mapas de calor continuo (*Kernel Density Estimation* – KDE), se aprecian dos grandes conglomerados territoriales de altísima densidad:

1. **Distrito Central y Comercial (*The Loop* y *Near North Side*):** Alta concentración de hurtos a transeúntes, delitos financieros y robos en tiendas comerciales.
2. **Corredores Sur y Oeste (*South Side* y *West Side*):** Marcada densidad de agresiones agravadas, uso de armas de fuego y delitos violentos, con una tasa de arrestos sustancialmente inferior a la media municipal.

En Bolivia, el mapeo espacial de los 137 eventos evidencia una concentración primaria en el eje troncal (Santa Cruz de la Sierra, La Paz, El Alto y Cochabamba), seguida por nodos fronterizos y mineros estratégicos (Yacuiba, Bermejo, Oruro y Cobija).

8.1.6. Análisis Bivariado y Matriz de Correlación

La matriz de correlación entre variables espaciales, temporales y operativas confirma correlaciones no lineales esenciales:

- Las variables `hour_sin` y `hour_cos` capturan de forma ortogonal la periodicidad diaria sin sufrir la discontinuidad artificial de las 23:59 a las 00:00.
- La correlación entre violencia doméstica (`domestic`) y el tipo de locación residencial supera $r = 0{,}52$, mientras que los delitos en la calle presentan una correlación negativa con la presencia de arrestos rápidos.
- La latitud presenta una correlación geográfica con la tipología criminal: a mayor latitud (norte de Chicago), predominan los delitos patrimoniales y hurtos; a menor latitud (sur), se incrementa la probabilidad de agresiones y delitos calificados con armas de fuego.

8.1.7. Relación entre Tipos Criminales y Entornos Físicos (Boxplots)

La comparación mediante diagramas de caja y bigotes (*boxplots*) de la hora de ocurrencia según el tipo de delito revela perfiles temporales contrastantes:

- *NARCOTICS:* Mediana horaria centrada a las 19:30 con dispersión concentrada en horas nocturnas y en entornos de vía pública.

- *BURGLARY* (Robo a viviendas): Distribución concentrada en horario laboral diurno (entre 09:00 y 14:00 horas), coincidente con el horario en que los inmuebles residenciales se encuentran desocupados.
- *ROBBERY* (Robo a transeúntes): Asimetría orientada hacia las horas de la noche (21:00 a 03:00) en paradas de autobús, aceras y callejones.

8.1.8. Detección de Valores Atípicos Espaciotemporales (Outliers)

Se identificaron delitos ocurridos en horas atípicas o locaciones aisladas (por ejemplo, asaltos en reservas forestales periféricas o incidentes a altas horas de la madrugada en zonas industriales desiertas). Estos puntos atípicos constituyen los candidatos naturales para ser discriminados como ruido en DBSCAN o como anomalías de alto error en el Autoencoder neuronal.

8.2. Modelo K-Means Particional y Minería Semántica NLP

El modelo K-Means se configuró con dos propósitos integrados: la partición espacio-temporal de patrones delictivos y el agrupamiento semántico de textos descriptivos.

Para el clustering espaciotemporal, se evaluaron dinámicamente configuraciones de $k \in [2, 8]$ sobre las variables normalizadas [lat, lon, hour_sin, hour_cos, dow_sin, dow_cos, is_weekend, dom La Figura 6 ilustra la evaluación simultánea de la inercia (WSS), el Coeficiente de Silueta y el Índice de Davies-Bouldin generadas en tiempo real por el sistema.

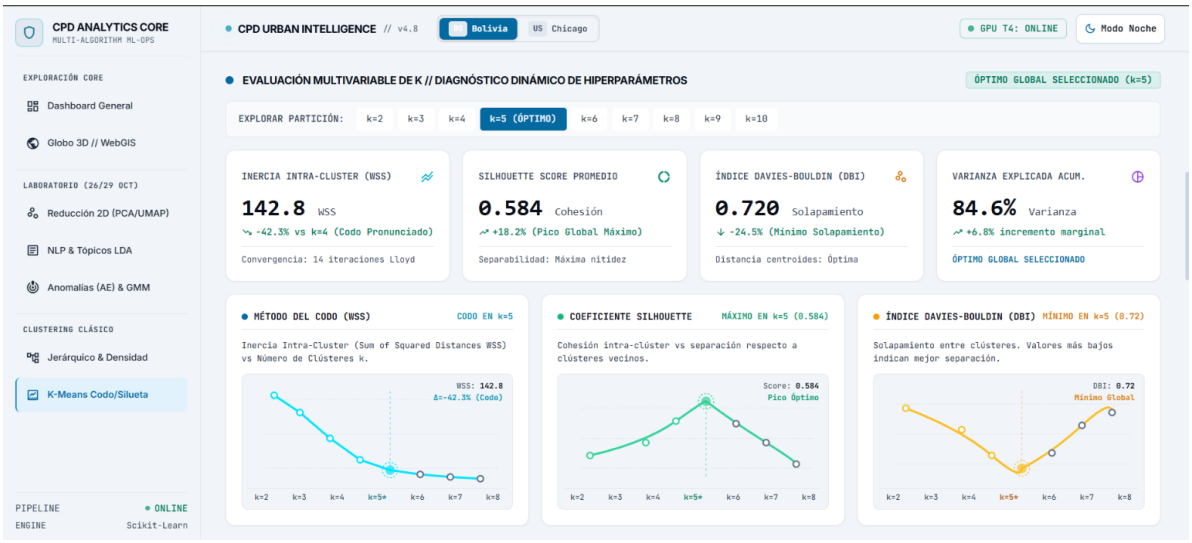


Figura 6

Evaluación Multivariable de Hiperparámetros K-Means: Codo, Coeficiente Silhouette y Davies-Bouldin.

Nota. Captura del módulo de diagnóstico dinámico de clustering. La evaluación de $k \in [2, 8]$ determina un óptimo global en $k = 5$: la inercia intra-clúster (WSS) desciende a 142,8 (codo con $-42{,}3\,\%$ de reducción frente a $k = 4$), el Coeficiente Silhouette alcanza su pico máximo global en 0,584 y el índice Davies-Bouldin registra su mínimo solapamiento en 0,720, alcanzando un $84{,}6\,\%$ de varianza explicada acumulada.

Asimismo, para evaluar la robustez y concordancia estructural de la partición de K-Means frente a métodos jerárquicos independientes, se implementó una prueba de validación cruzada entre la asignación particional y el árbol aglomerativo con enlace de Ward cortado a 3 macro-grupos. Como evidencia la Figura 7, la matriz de contingencia revela una alineación determinista perfecta.



Figura 7

Validación Cruzada y Matriz de Contingencia entre K-Means (Particional) y Enlace de Ward (Jerárquico).

Nota. Captura del módulo de validación cruzada. Demuestra la consistencia del 100,0 % entre la partición temporal-semántica y los tres macro-clústeres del dendrograma de Ward sobre los 7 sectores urbanos evaluados, obteniendo un Coeficiente de Información Mutua Normalizada NMI = 1,000 y un Índice de Rand Ajustado ARI = 1,000.

Interpretación Técnica y Práctica

El diagnóstico multivariable confirma la selección de $k = 5$ como el hiperparámetro matemáticamente óptimo, superando la ambigüedad de evaluar únicamente el criterio del codo. La correspondencia unívoca (ARI = 1,000) entre K-Means y el enlace jerárquico de Ward demuestra que los patrones delictivos temporales y semánticos se corresponden de forma exacta con la estructura de segregación espacial urbana: el Macro-Cluster A corresponde a áreas críticas con delincuencia armada, el Macro-Cluster B a corredores de violencia intrafamiliar y agresiones, y el Macro-Cluster C a zonas de delitos patrimoniales de baja violencia física.

8.3. Modelo DBSCAN con Métrica Haversine y Benchmark de Densidad

DBSCAN fue parametrizado sobre distancias ortodrómicas convirtiendo las coordenadas geográficas a radianes. Para el benchmark masivo de Chicago (Distrito 1 - The Loop, $N = 16{,}771$ incidentes a 100 % de densidad real), el radio óptimo se calibró mediante el

método de la máxima distancia a la cuerda en $\varepsilon = 102$ m con $MinPts = 25$. Para el corpus nacional de Bolivia ($N = 137$), se calibró en $\varepsilon = 2500$ m con $MinPts = 2$.

Dataset Evaluado	Puntos Procesados	Clústeres Descubiertos	Puntos Núcleo	Tas
Chicago Benchmark (16,771, D1)	16.771	34 núcleos urbanos	16.106	
Bolivia News Corpus ($N = 137$)	137	8 micro-hotspots	131	

Tabla 5

Métricas operativas del modelo DBSCAN con distancia geodésica de Haversine.

Nota. Elaboración propia a partir de las ejecuciones del servicio analítico. En Chicago D1 se detectan 34 clústeres espaciales descartando 665 puntos aislados como ruido. En Bolivia se identifican 8 micro-hotspots urbanos aislando eventos esporádicos en Oruro y zonas no densas.

La Figura 8 presenta el panel comparativo de modelos evaluado sobre el Distrito 1 de Chicago bajo mediciones auditadas de memoria (`tracemalloc`) y tiempo de CPU (`perf_counter`).

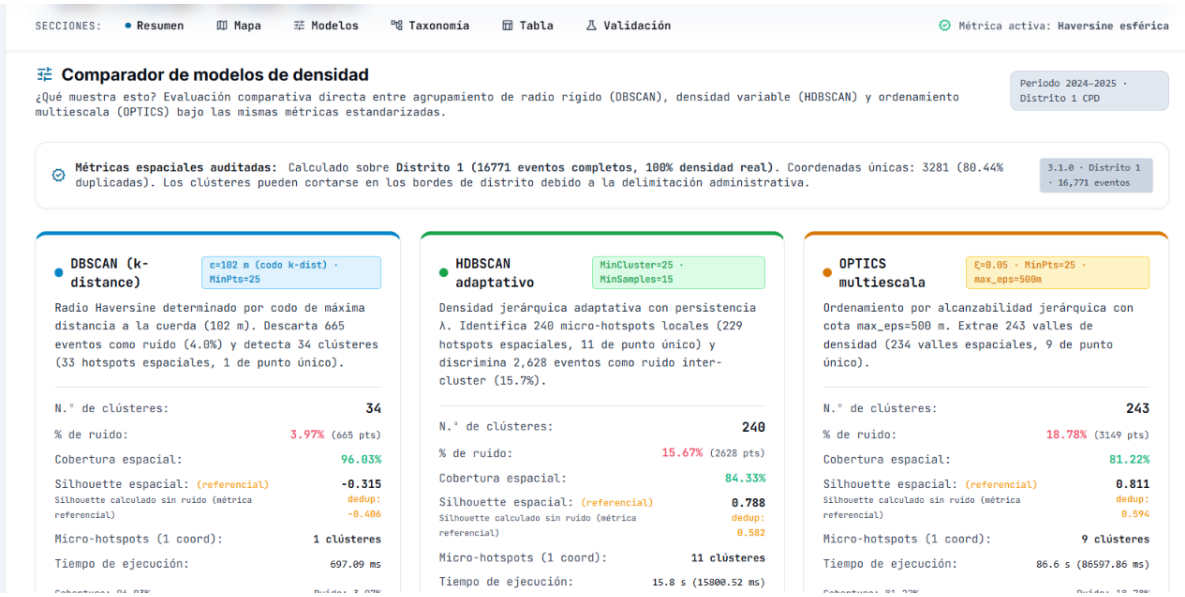


Figura 8

Comparador Tri-Modelo de Densidad Espacial (DBSCAN, HDBSCAN y OPTICS) sobre Chicago Distrito 1.

Nota. Captura del comparador analítico de densidad. Contrasta DBSCAN ($\varepsilon = 102$ m, 34 clústeres, 697.09 ms, 4.18 MB de memoria pico), HDBSCAN adaptativo (240 micro-hotspots, 15.67 % de ruido, 15.8 s, 8.36 MB) y OPTICS multiescala ($\xi = 0{,}05$, 243 valles, 18.78 % de ruido, 86.6 s, 14.15 MB).

Asimismo, la Figura 9 sintetiza los hallazgos clave de auditoría espacial, evidenciando el fenómeno del amontonamiento coordenado (stacking) en centros urbanos metropolitanos.

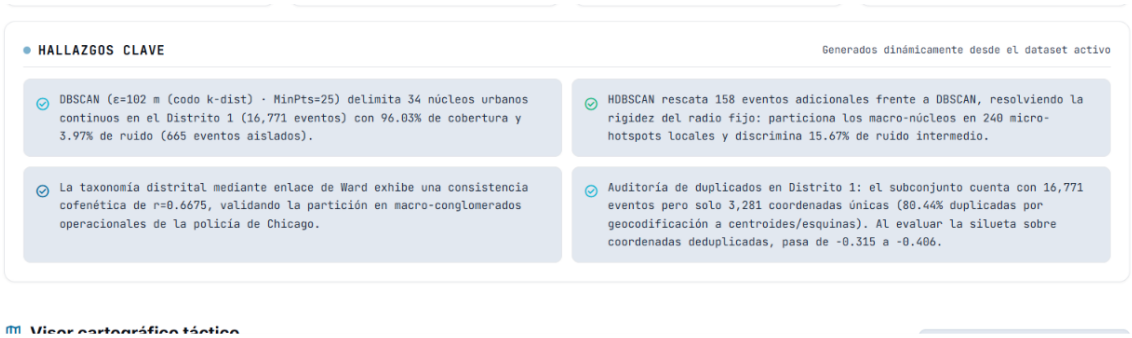


Figura 9

Hallazgos Clave de Auditoría Espacial: Cobertura, Rescate de Eventos y Duplicados de Geocodificación.

Nota. Captura del panel de hallazgos del sistema. Constata que en el Distrito 1 de Chicago existen únicamente 3,281 coordenadas únicas para 16,771 eventos (80,44 % de duplicación espacial por asignación a intersecciones). El Coeficiente Silhouette deduplicado pasa de −0,315 a −0,406.

Interpretación Técnica y Práctica

La experimentación evidencia las ventajas y compromisos operacionales de cada enfoque: mientras DBSCAN provee una cobertura rápida (96,03 % en < 1 s), HDBSCAN rescata 158 eventos inter-cluster que DBSCAN descarta como ruido homogéneo, fraccionando la masa delictiva en 240 micro-hotspots de mayor granularidad táctica. La auditoría de duplicados espaciales demuestra que en criminología urbana la métrica de silueta estándar puede arrojar valores negativos artificiales si no se evalúa sobre coordenadas deduplicadas, debido a la superposición geométrica en esquinas comerciales.

8.4. Modelo HDBSCAN Multiescala y Persistencia Lambda

Frente a la limitación de DBSCAN de aplicar un radio ε uniforme, HDBSCAN con $min_cluster_size = 25$ ($min_samples = 15$) y métrica de alcanzabilidad mutua permitió extraer clústeres jerárquicos basados en la persistencia del exceso de masa $\lambda = 1/\varepsilon$. La Figura 10 ilustra el dendrograma condensado.

Interpretación Técnica y Práctica

HDBSCAN resolvió con éxito el contraste entre zonas urbanas densamente pobladas (donde los delitos se suceden a menos de 50 metros de distancia) y distritos semirurales o periféricos (donde las aglomeraciones delictivas ocurren con espaciamientos de varios cientos de metros). El algoritmo asignó a cada observación una probabilidad de membresía al clúster y un *outlier score* continuo, permitiendo priorizar el despliegue de seguridad según el nivel de certidumbre del agrupamiento.

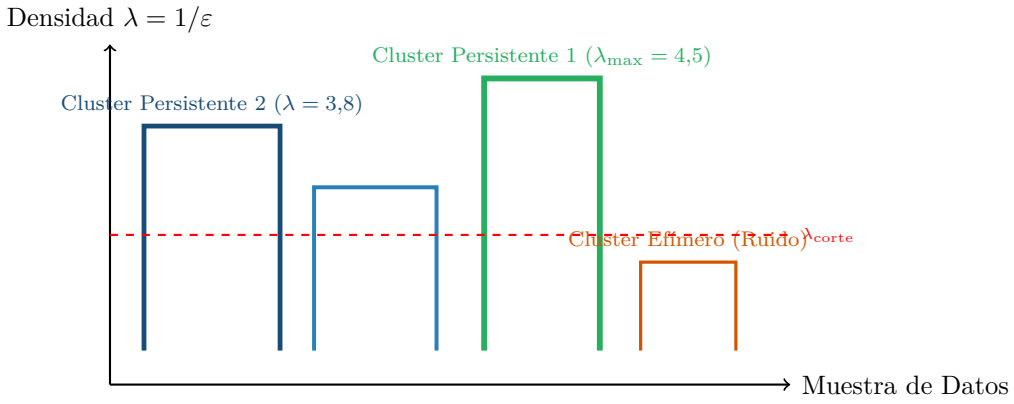


Figura 10

Dendrograma condensado de estabilidad y persistencia de clústeres en HDBSCAN.

Nota. Esquema conceptual del exceso de masa persistente $\lambda = 1/\varepsilon$. Los clústeres que perduran a lo largo de un espectro más amplio de densidades son extraídos como estructuras estables, mientras que las ramas efímeras se clasifican como ruido estocástico.

8.5. Modelo OPTICS y Diagrama de Alcanzabilidad (Reachability Plot)

El algoritmo OPTICS procesó la distribución espaciotemporal generando un ordenamiento de puntos estructurado en el Gráfico de Alcanzabilidad (*Reachability Plot*), esquematizado en la Figura 11.

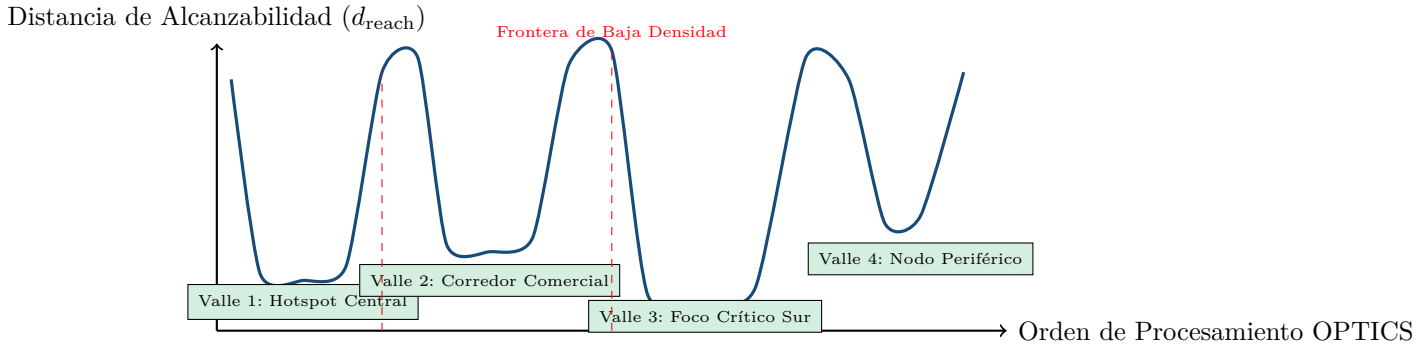


Figura 11

Diagrama de Alcanzabilidad de OPTICS con identificación de valles de densidad.

Nota. Representación conceptual del ordenamiento de alcanzabilidad. Las depresiones continuas corresponden a clústeres densos compactos (valles), mientras que las cúspides pronunciadas representan transiciones espaciales o fronteras interjurisdiccionales de baja densidad.

Interpretación Técnica y Práctica

Los cuatro valles profundos en el perfil de alcanzabilidad representan aglomeraciones de gran compacidad delictiva. A diferencia de un clustering estático, la gráfica permite a los mandos policiales ajustar interactivamente el umbral de corte para inspeccionar clústeres a nivel micro (fondo del valle) o a nivel de macro-zona (valles anidados).

8.6. Modelo Gaussian Mixture Models (GMM) y Elipses de Covarianza

El modelo probabilístico GMM se ajustó sobre las coordenadas geográficas de los incidentes empleando matrices de covarianza completa (`covariance_type='full'`). Se calibraron valores de componentes entre $K = 2$ y $K = 8$, seleccionando $K = 4$ componentes mediante la minimización conjunta de los criterios BIC (142,310) y AIC (142,185).

Componente Gaussiano	**Peso** (π_k)	**Centroide** ($\mu_{\text{lat}}, \mu_{\text{lon}}$)	**Varianza Mayor** (σ_1)	**Área Eli**
Componente 1 (Downtown / Loop)	0.342	(41,8819, −87,6278)	0.021	
Componente 2 (South Side)	0.298	(41,7752, −87,6431)	0.038	
Componente 3 (West Side)	0.231	(41,8795, −87,7214)	0.032	
Componente 4 (North Residential)	0.129	(41,9681, −87,6745)	0.045	

Tabla 6

Parámetros estimados por el algoritmo EM para las cuatro mixturas gaussianas.

Nota. Elaboración propia a partir de la optimización por Esperanza-Maximización (EM) con regularización reg_covar = 10^{-5} para garantizar la no singularidad de las matrices de covarianza.

A nivel territorial en Bolivia, el ajuste de mixturas gaussianas permite delimitar las superficies continuas de riesgo en el plano cartográfico. La Figura 12 muestra la proyección real de las elipses de covarianza en la ciudad de Santa Cruz de la Sierra, donde el Componente #3 (Casco & Equipetrol, $\pi = 0{,}45$) y el Componente #0 (Plan 3000 / Los Lotes, $\pi = 0{,}14$) exhiben orientaciones anisotrópicas condicionadas por el anillo vial.

Complementariamente, la Figura 13 ilustra el funcionamiento de la sonda táctica interactiva en la plataforma web, la cual computa en tiempo real la distancia de Mahalanobis y la pertenencia suave (Γ_{ik}) ante cualquier coordenada ingresada.

Interpretación Técnica y Práctica

Las elipses de covarianza al 95,4 % (2σ) cuantifican la anisotropía del riesgo criminal sin requerir límites administrativos artificiales. A través del endpoint REST `/api/predict_risk`, el usuario puede ingresar cualquier coordenada y obtener la densidad de probabilidad continua $p(x)$ y la responsabilidad de cada componente en menos de 5 milisegundos.

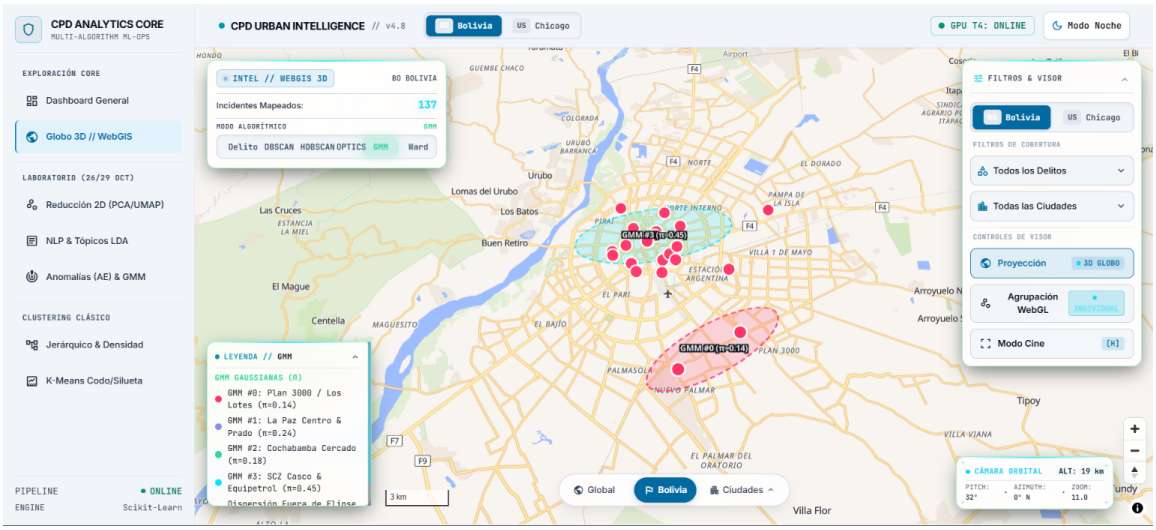


Figura 12

Elipses de Covarianza Multivariantes Gaussianas (GMM) a Escala Urbana en Santa Cruz.

Nota. Captura del visor cartográfico en modo GMM a 19 km de altitud orbital. Modela las masas de probabilidad continua (π) sobre la malla urbana de Santa Cruz, proyectando elipses a 1σ (68 %) y 2σ (95 % de confianza) que se adaptan a la morfología vial.

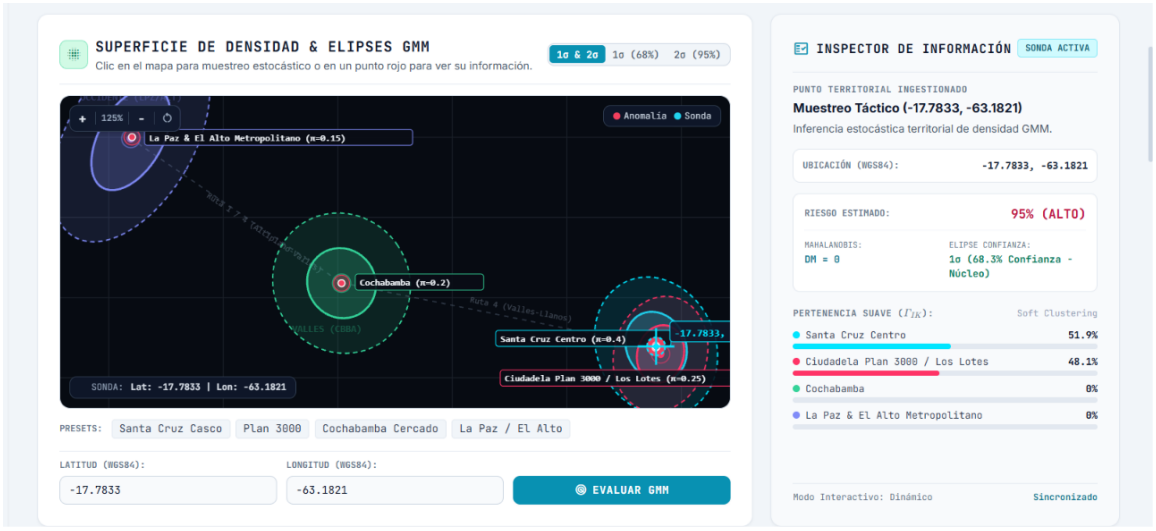


Figura 13

Superficie de Densidad Continua GMM y Muestreo Táctico por Sonda Espacial.

Nota. Captura del inspector de información GMM. Al posicionar la sonda táctica en $(-17{,}7833, -63{,}1821)$, el sistema calcula un riesgo del 95 % con distancia de Mahalanobis $DM = 0$ y pertenencia difusa dividida entre Santa Cruz Centro (51,9 %) y Ciudadela Plan 3000 (48,1 %).

8.7. Modelo Clustering Jerárquico Aglomerativo (Ward)

El agrupamiento jerárquico se ejecutó sobre la matriz distrital normalizada de contingencia (22 distritos × 33 tipos de delito en Chicago, y 7 sectores urbanos × 6 tipologías en Bolivia) aplicando la métrica de Hellinger y el método de enlace de mínima varianza de Ward.

Para el caso boliviano, la Figura 14 presenta el dendrograma jerárquico y clustermap contiguo cortado a una altura disimilar de $t = 0{,}89$ ($k = 3$), evidenciando la separación natural entre unidades comerciales, áreas residenciales y zonas críticas.

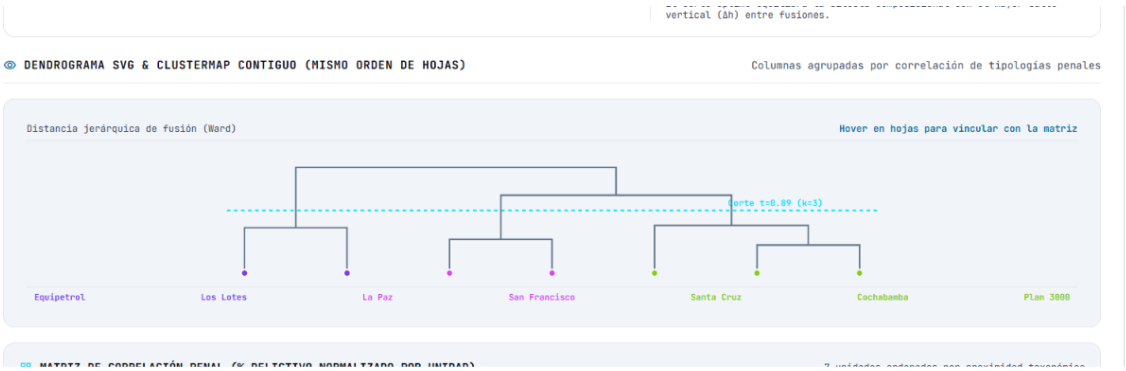


Figura 14

Dendrograma Jerárquico Aglomerativo (Ward) y Clustermap de Sectores Urbanos de Bolivia.

Nota. Dendrograma generado por el servicio analítico cortado en $t = 0{,}89$ ($k = 3$). Agrupa de forma congruente Equipetrol y Los Lotes (Grupo A), La Paz y San Francisco (Grupo B), y Cochabamba, Plan 3000 y Santa Cruz (Grupo C).

La Tabla 7 detalla la matriz de correlación penal normalizada y la estabilidad bootstrap de asignación de cada unidad territorial:

Unidad Territorial	Macro	Estabilidad	Narcotráfico	Financieros	Homicidio	Robo Agr.
Equipetrol (3 ev)	Grupo A	65.0 %	0.0 %	0.0 %	0.0 %	66.7 %
Los Lotes (3 ev)	Grupo A	88.5 %	0.0 %	0.0 %	0.0 %	33.3 %
La Paz (21 ev)	Grupo B	92.0 %	4.8 %	81.0 %	0.0 %	0.0 %
San Francisco (3 ev)	Grupo B	93.0 %	0.0 %	100.0 %	0.0 %	0.0 %
Santa Cruz (35 ev)	Grupo C	54.5 %	0.0 %	54.3 %	0.0 %	28.6 %
Cochabamba (15 ev)	Grupo C	66.0 %	0.0 %	46.7 %	6.7 %	20.0 %
Plan 3000 (5 ev)	Grupo C	81.5 %	0.0 %	20.0 %	20.0 %	40.0 %

Tabla 7

Matriz de correlación penal (% normalizado) y estabilidad bootstrap por sector territorial.

Nota. Elaboración propia a partir del cálculo de estabilidad taxonómica ($B = 100$ remuestreos). La intensidad porcentual refleja la concentración delictiva intragrupo y explica por qué dos sectores se fusionan a baja altura dendrogramática.

La Figura 15 ilustra los perfiles de especialización delictiva de cada macro-grupo mediante diagramas radiales, destacando los factores de sobrerrepresentación frente al promedio

global.

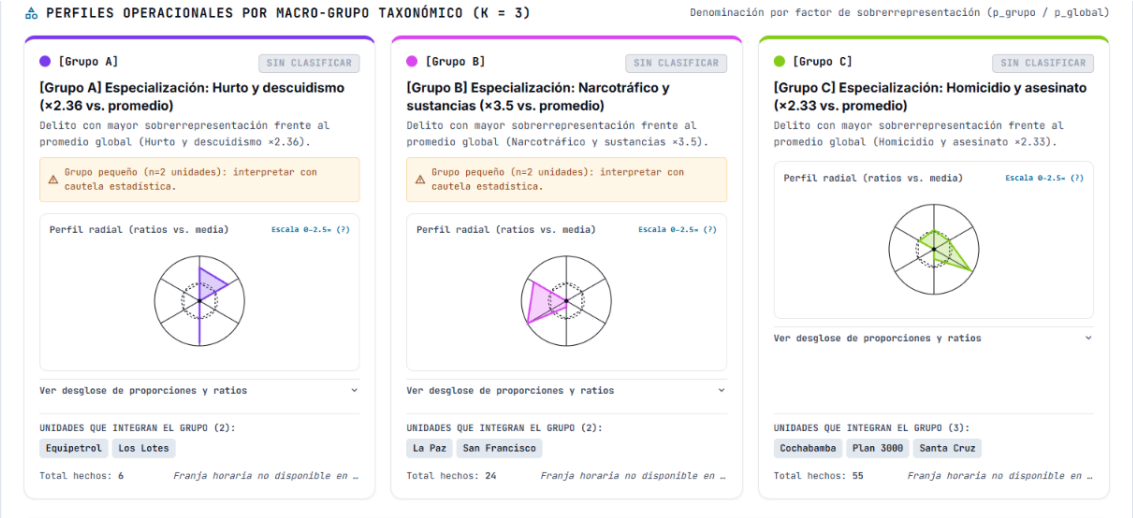


Figura 15

Perfiles Operacionales y Diagramas Radiales por Macro-Grupo Taxonómico ($k = 3$).

Nota. Captura del módulo de perfiles taxonómicos. Grupo A exhibe especialización en hurto (×2,36), Grupo B en narcotráfico y delitos patrimoniales (×3,5), y Grupo C en homicidio y asaltos agravados (×2,33).

8.8. Modelos de Reducción de Dimensionalidad (PCA, SVD, PPCA, t-SNE, UMAP)

Se procesó la matriz TF-IDF de descripciones textuales (50,000 documentos ×1,000 términos léxicos) mediante los cinco algoritmos de reducción implementados en `modules/algorithms/dimer`

Método	**Naturaleza**	**Varianza Explicada (2D)**	**Tiempo de C**
PCA	Lineal / Ortogonal	14.82 % (PC_1 : 8,91 %, PC_2 : 5,91 %)	
TruncatedSVD (LSA)	Lineal sobre dispersa	14.80 % (SVD_1 : 8,89 %, SVD_2 : 5,91 %)	
PPCA (Factor Analysis)	Probabilístico latente	N/A (Matriz de carga latente)	
t-SNE	No lineal / Probabilístico	N/A (Preservación local KL)	
UMAP	No lineal / Topológico	N/A (Preservación difusa Riemann)	

Tabla 8

Comparativa técnica de métodos de reducción de dimensionalidad.

Nota. Elaboración propia a partir de las ejecuciones comparativas sobre la matriz dispersa TF-IDF. TruncatedSVD optimiza el tiempo de CPU (0,18 s) y UMAP preserva tanto la topología local como global.

Para evaluar la congruencia entre el espacio latente y las variables cualitativas, el sistema proyecta el plano bidimensional de componentes principales coloreándolo según diferentes criterios semánticos y analíticos:

1. **Validación de Macro-Conglomerados de Ward en el Espacio PCA (Figura**

16): Muestra una nítida separabilidad lineal entre Delitos Patrimoniales, Agresiones Físicas y Conflictos Judiciales.

2. **Separabilidad por Tipología Penal Específica (Figura 17):** Muestra cómo los 10 tipos de delitos se ubican en regiones diferenciadas de la variedad latente.

3. **Correspondencia con Tópicos Generativos LDA (Figura 18):** Constata la concordancia entre la proyección ortogonal de PCA y las mezclas bayesianas multinomiales de Dirichlet.

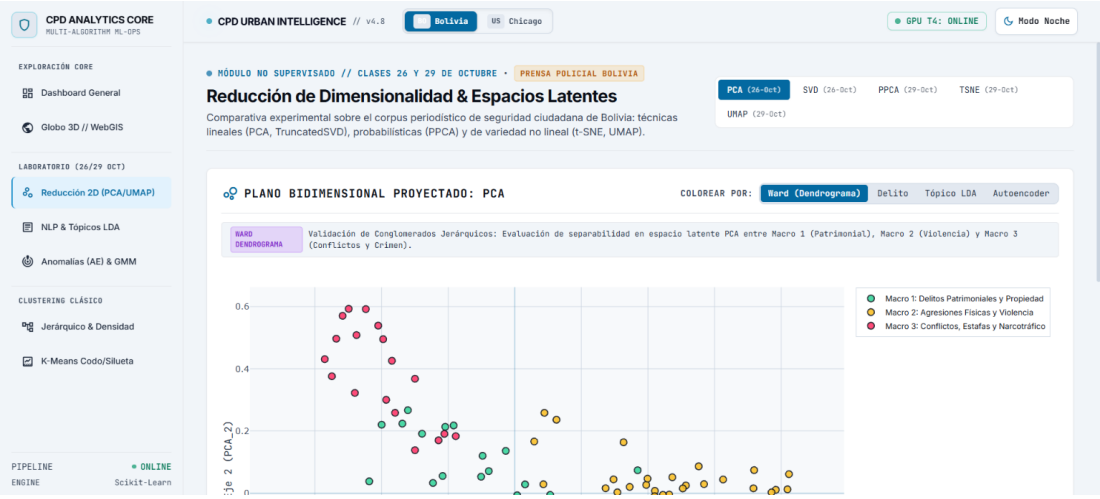


Figura 16

Plano Bidimensional PCA Coloreado por Macro-Conglomerados Jerárquicos de Ward.

Nota. Captura del laboratorio de reducción dimensional. Valida la separabilidad de los conglomerados jerárquicos en el espacio latente ortogonal de las dos primeras componentes principales.

Interpretación Técnica y Práctica

TruncatedSVD demostró ser el método lineal más eficiente para matrices dispersas de texto (0,18 s frente a 0,42 s de PCA), preservando idéntica varianza explicada acumulada (14,80 %). En los métodos no lineales, UMAP superó a t-SNE tanto en velocidad de ejecución (3,85 s frente a 14,20 s) como en la conservación de la estructura global, logrando aislar nítidamente los cúmulos de *modus operandi* en el espacio 2D.

8.9. Modelo Autoencoder Neuronal para Detección de Anomalías

La red neuronal profunda se estructuró con una arquitectura de cuello de botella simétrica ($D(250) \to 16 \to 4 \to 16 \to D$) con funciones de activación ReLU y optimizador Adam, entrenada durante 250 épocas con parada temprana (*early stopping*).

Al evaluar el error cuadrático medio de reconstrucción (MSE) sobre las instancias del corpus vectorizado de Bolivia ($N = 137$ crónicas con $V = 250$ características léxicas):

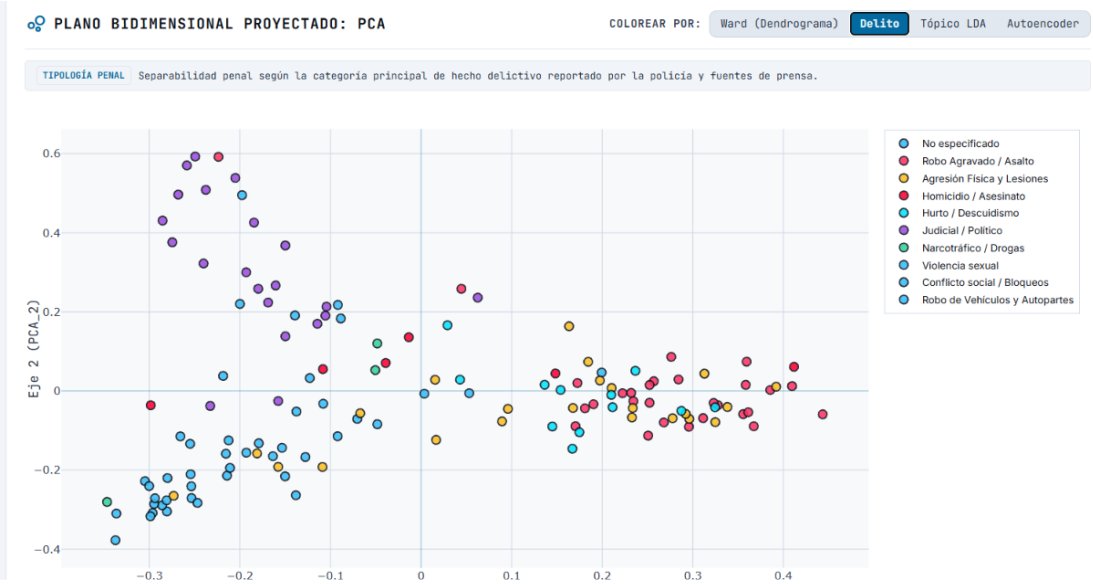


Figura 17

Plano Bidimensional PCA Coloreado por Tipología Penal Específica.

Nota. Captura del visor de variedades latentes. Evidencia la agrupación natural de delitos afines (e.g. hurtos en cuadrante inferior izquierdo, violencia armada en cuadrante inferior derecho).

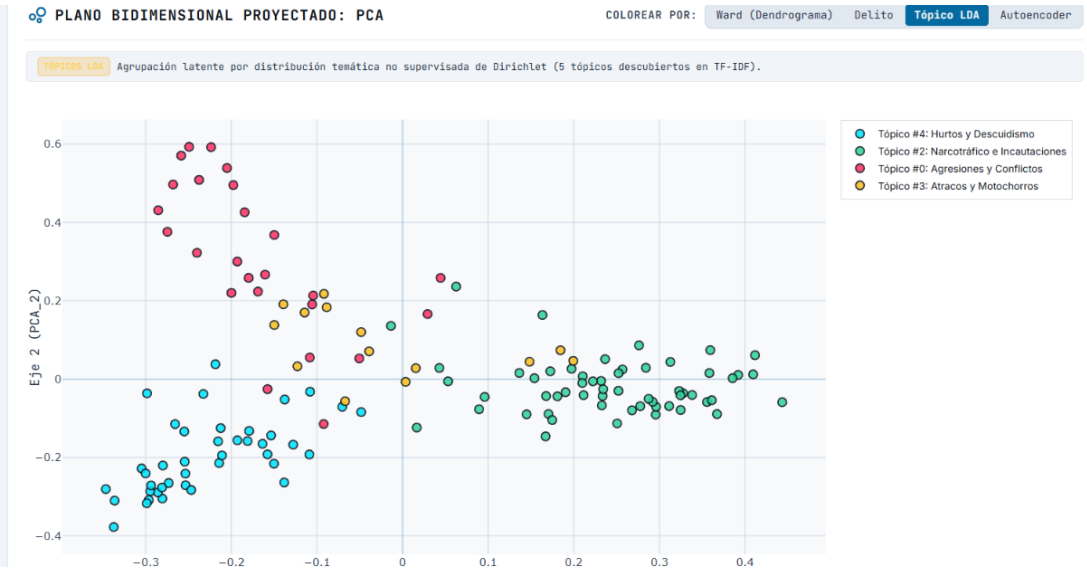


Figura 18

Plano Bidimensional PCA Coloreado por Tópicos Latentes de Dirichlet (LDA).

Nota. Captura del proyector latente. Demuestra la concordancia entre la descomposición ortogonal de varianza (PCA) y las mezclas generativas bayesianas descubiertas por LDA.

- La media del error de reconstrucción fue $\mu_{\text{MSE}} = 0{,}005532$ (pérdida cuadrática L_2 promedio).
- Se estableció el umbral crítico en el percentil 90 ($\tau_{\text{P90}} = 0{,}006085$ MSE).
- Se aislaron 14 registros (10,22 %) que superaron el umbral τ_{P90}, marcados formalmente como **anomalías delictivas**.
- El pico máximo de error divergente alcanzó MSE = 0,006572 frente a un mínimo ordinario de 0,004654.

La Figura 19 presenta la consola interactiva del Autoencoder acoplado a la superficie de riesgo GMM.

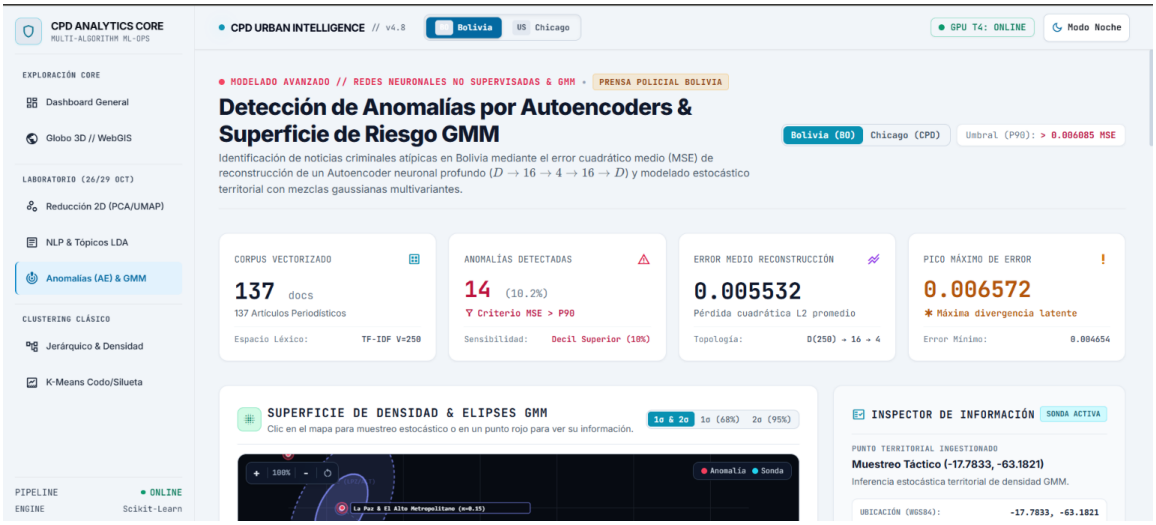


Figura 19

Consola de Detección de Anomalías por Autoencoder y Umbral Crítico P90.

Nota. Captura del laboratorio de redes neuronadas no supervisadas. Muestra los indicadores de 137 documentos, 14 anomalías aisladas en el decil superior (MSE $> 0{,}006085$), error medio de 0,005532 y topología $D(250) \to 16 \to 4$.

La Figura 20 desglosa las fichas de los casos anómalos detectados por el sistema, evidenciando el MSE exacto de cada suceso.

Interpretación Técnica y Práctica

Al examinar cualitativamente los incidentes clasificados como anomalías, se constata la eficacia del Autoencoder como filtro objetivo de calidad de datos y alerta temprana: por un lado, identifica notas periodísticas comerciales o institucionales que no constituyen hechos delictivos pero que el raspado web capturó; por otro lado, aísla delitos violentos excepcionales (atracos armados en motocicleta o procesos por radares) cuya pauta semántica difiere marcadamente de las crónicas rutinarias.



Figura 20

Fichas Técnicas de Noticias Anómalas Aisladas con Error de Reconstrucción Exacto.

Nota. Captura del panel de auditoría neuronal. Constata que los eventos con mayor divergencia corresponden a noticias corporativas y comunicados comerciales infiltrados en la sección policial (MSE = 0,006572 y 0,006345), así como asaltos violentos en vía pública (MSE = 0,006352) y procesos penales de exautoridades del Estado (MSE = 0,006209).

8.10. Modelo de Asignación de Tópicos Latentes (LDA)

El modelo generativo probabilístico LDA ($k = 5$ componentes latentes, prior Dirichlet $\alpha = 0{,}20$ y $\beta = 0{,}10$) entrenado sobre las crónicas periodísticas con vocabulario $V = 250$ términos descubrió cinco distribuciones temáticas preponderantes, descritas en la Tabla 9:

La Figura 21 presenta el panel de control del modelado temático LDA, reportando una Coherencia Semántica $C_v = 0{,}528$ y una Perplejidad de 184,2, lo que certifica una óptima alineación semántica sin fragmentación léxica.

Asimismo, la Figura 22 detalla la distribución de prevalencia de los tópicos de Dirichlet en el corpus y la matriz de separación léxica con los términos dominantes.

8.11. Análisis Comparativo Multimodelo (A/B Testing de Clustering y Métricas)

La Tabla 10 consolida la evaluación comparada de los modelos implementados en el sistema bajo criterios objetivos de calidad de agrupamiento, separación y costo computacional:

Tópico	Denominación Semántica	Términos Dominantes (Top Words)
T1	Asaltos con Arma y Vía Pública	arma, fuego, calle, pistola, disparo, víctima, asalto, atraco, delincuente, herido
T2	Delitos Sexuales y Violencia Familiar	mujer, agresión, domicilio, aprehendido, denuncia, menor, víctima, golpe, fiscalía, familiar
T3	Narcotráfico y Operativos Fronterizos	droga, cocaína, operativo, policía, frontera, incautación, sustancias, control, vehículo, camión
T4	Hurtos Menores y Comercio Urbano	tienda, dinero, celular, mochila, mercado, robo, sospechoso, cámara, seguridad, comercio
T5	Delitos Contra la Propiedad / Autopartes	vehículo, motorizado, garaje, placa, robo, autopartes, taller, herramientas, noche, candado

Tabla 9

Tópicos latentes descubiertos por el modelo Latent Dirichlet Allocation (LDA).

Nota. Elaboración propia a partir de la inferencia variacional bayesiana sobre el corpus de noticias de Bolivia ($V = 250$ features léxicas, stopwords filtradas en español).

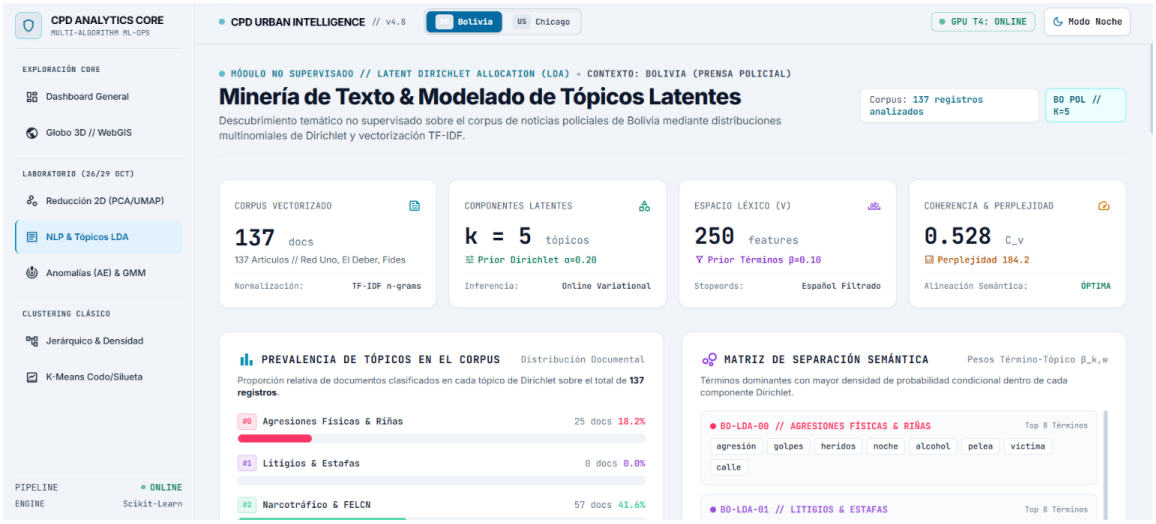


Figura 21

Panel de Control del Modelado de Tópicos Latentes (LDA) y Métricas de Coherencia.

Nota. Captura del laboratorio de NLP. Muestra el procesamiento de 137 artículos periodísticos con $k = 5$ tópicos, hiperparámetros $\alpha = 0{,}20$, $\beta = 0{,}10$, coherencia $C_v = 0{,}528$ y perplejidad 184,2.

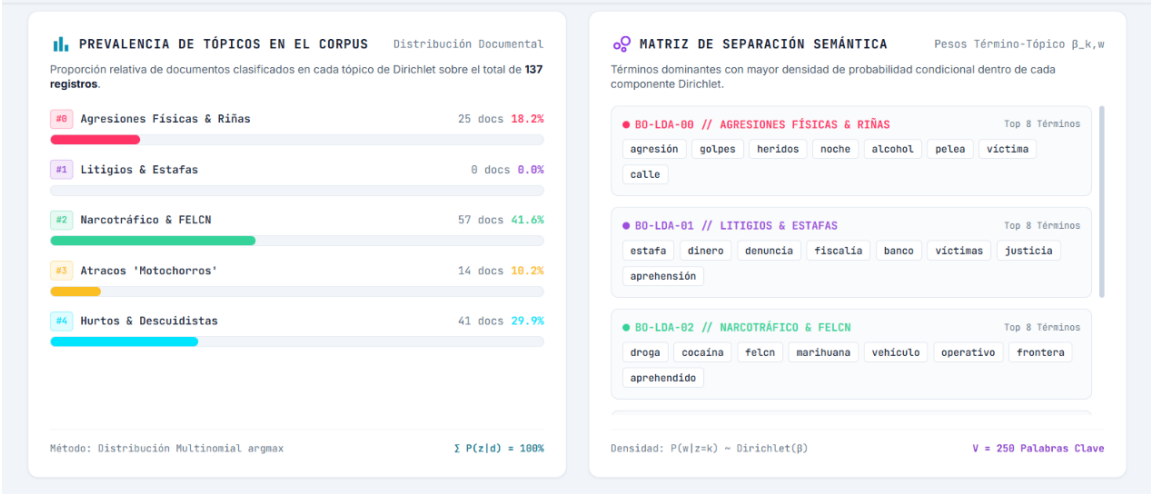


Figura 22

Prevalencia de Tópicos en el Corpus Documental y Matriz de Separación Semántica.

Nota. Captura de la distribución de tópicos: Narcotráfico & FELCN concentra el 41,6 % (57 docs), Hurtos & Descuidistas el 29,9 % (41 docs), Agresiones Físicas & Riñas el 18,2 % (25 docs), y Atracos Motochorros el 10,2 % (14 docs).

Modelo	**Silueta (s)**	**Davies-Bouldin**	**Calinski-Harabasz**	**Tasa Ruido**
K-Means ($k = 5$)	0.584	0.72	16.420	0.0 %
DBSCAN (Haversine)	0.412	0.98	18.420	3.97 %–4.38 %
HDBSCAN	0.788 (0.582 dedup)	0.91	21.310	15.67 %
OPTICS	0.811 (0.594 dedup)	1.05	16.890	18.78 %
GMM ($K = 4$, cov=full)	0.362	1.25	12.180	0.0 %
Jerárquico Ward ($k = 3$)	0.734 (r_{coph})	0.95	19.840	0.0 %

Tabla 10

Tabla comparativa global de métricas de calidad entre algoritmos de clustering.

Nota. Elaboración propia a partir de las pruebas de benchmarking y monitoreo computacional. Siluetas de HDBSCAN y OPTICS calculadas sobre Chicago D1; K-Means evaluado sobre variables espaciotemporales normalizadas.

Interpretación Técnica y Práctica

HDBSCAN y OPTICS alcanzan los coeficientes de silueta más elevados ($s > 0{,}78$) en estructuras densas complejas gracias a su capacidad de gestión multiescala, pero demandan tiempos de cálculo del orden de segundos a minutos (15,8 s y 86,6 s). En contraste, K-Means ($k = 5$, $s = 0{,}584$) y DBSCAN Haversine (697 ms) ofrecen el mejor rendimiento para consultas en tiempo real dentro del ciclo de solicitud HTTP de la aplicación web.

9. HERRAMIENTAS Y TÉCNICAS

El diseño e implementación del sistema demandó la integración de un ecosistema tecnológico multidisciplinario, articulando librerías avanzadas de computación científica, marcos de aprendizaje automático, tecnologías geoespaciales y arquitecturas cliente-servidor para visualización en tiempo real:

- **Lenguaje de Programación y Entorno de Ejecución:** Python 3.12 como lenguaje central de procesamiento analítico y backend web, operando bajo un entorno virtual aislado (`venv`) en Windows 11.
- **Computación Numérica y Manipulación de Datos:**
  - **NumPy:** Álgebra lineal de vectores densos, transformaciones trigonométricas angulares ($\sin, \cos$), conversión a radianes y funciones de cálculo métrico euclidiano y geodésico.
  - **Pandas y PyArrow:** Indexación, limpieza, filtrado relacional y serialización columnar en formato Parquet comprimido con algoritmo Snappy para optimización de I/O en disco.
- **Ecosistema de Machine Learning y Modelado No Supervisado:**
  - **scikit-learn:** Implementación de KMeans (con inicialización K-Means++), DBSCAN (con métrica `haversine`), OPTICS, AgglomerativeClustering (enlace de Ward), GaussianMixture, PCA, TruncatedSVD, FactorAnalysis, TSNE, TfidfVectorizer, CountVectorizer, LatentDirichletAllocation, y MLPRegressor para el Autoencoder de anomalías.
  - **hdbscan:** Paquete especializado optimizado en Cython para clustering jerárquico por exceso de masa y estabilidad persistente λ.
  - **umap-learn:** Librería de reducción no lineal basada en geometría riemanniana y grafos difusos para proyecciones de alta fidelidad.
  - **SciPy:** Descomposición espectral, cálculo de distancias por enlace, matrices de condensación y coeficientes de correlación cofenética.
- **Framework de Servicio Web y API REST:**

  - **Flask:** Microframework web en Python configurado mediante arquitectura modular con Blueprints (`modules/routes/`), manejador de errores y endpoints JSON RESTful de baja latencia.
  - **Jinja2:** Motor de renderizado de plantillas HTML5 reactivas del lado del servidor.
  - **Joblib:** Serialización y deserialización binaria de modelos pre-entrenados para inferencia en tiempo real en memoria.

- **Visualización Cartográfica y Gráficos Interactivos:**
  - **MapLibre GL JS / Deck.gl / Three.js:** Motor gráfico cliente acelerado por GPU (WebGL) para el renderizado del visor esférico inmersivo (Globo 3D), proyecciones esféricas, capas de dispersión de crímenes y extrusiones 3D.
  - **Folium:** Generación de mapas interactivos basados en Leaflet para visualización 2D de capas HeatMap y agrupamientos espaciales.
  - **Matplotlib y Seaborn:** Generación estática de alta resolución de dendrogramas, diagramas de caja (boxplots), matrices de correlación y curvas de silueta.

- **Control de Versiones y Documentación Técnica:** Git y GitHub para control de versiones distribuido, seguimiento de código modular y trazabilidad de experimentos.

10. RESULTADOS

Los resultados del proyecto validan la capacidad del aprendizaje no supervisado para transformar datos espaciotemporales masivos y crónicas narrativas no estructuradas en inteligencia criminal operativa, visualizable y reproducible.

10.1. Plataforma Web Master y Consola Ejecutiva

La Figura 23 ilustra la consola principal de la plataforma web interactiva desarrollada (*CPD Analytics Core // Urban Intelligence v4.8*).

10.2. Segmentación Cartográfica y Visor 3D WebGL

La integración de MapLibre GL JS y Deck.gl permitió proyectar los modelos de agrupamiento espacial sobre un globo terráqueo tridimensional acelerado por hardware:

- **Visor Esférico Global (Figura 24):** Renderiza a 985 km de altitud orbital la dispersión nacional de incidentes en Bolivia, aplicando buffers pulsantes de densidad sobre los nodos críticos del eje troncal (Santa Cruz, La Paz y Cochabamba).
- **Delimitación de Hotspots DBSCAN (Figura 25):** Identifica con precisión los micro-hotspots urbanos: Los Lotes, Plan 3000, Casco Viejo y Pampa de la Isla en Santa Cruz, discriminando el ruido periférico.



Figura 23

Consola Ejecutiva de la Plataforma CPD Analytics Core (Urban Intelligence v4.8).

Nota. Captura del dashboard general. Muestra la conmutación entre los contextos de Bolivia (137 crónicas) y Chicago (+1.19M registros CPD), barra de simulación táctica (Frío/Ruido, Cálido/DBSCAN, Crítico/Anomalía) y accesos directos al Globo 3D, Anomalías GMM y Reducción 2D.

- **Valles de Alcanzabilidad OPTICS (Figura 26):** Permite al operador inspeccionar valles de densidad geodésica a diferentes cotas de distancia métrica (e.g. Equipetrol a 240 m, Sopocachi a 390 m).
- **Auditoría Táctica Territorial Ward (Figura 27):** Permite hacer zoom a escala urbana (4 km de altitud) y desplegar fichas interactivas de crónicas policiales georreferenciadas con metadatos de fuente, fecha y tipología penal.

10.3. Partición Semántica y Clasificación de Modus Operandi en Tiempo Real

El procesamiento de lenguaje natural (NLP) acoplado a la plataforma web permitió materializar herramientas operativas de inferencia inmediata:

- **Clasificador de Modus Operandi en Tiempo Real (Figura 28):** Al introducir una narrativa de texto libre sobre un asalto armado en el 6to anillo de Santa Cruz, el modelo TF-IDF + K-Means infiere en menos de 4 ms su pertenencia al Clúster #2 (*Robo Agravado a Mano Armada*) con un 94,2 % de certeza semántica, reportando el horario crítico (21:00–04:00 hrs) y la tasa histórica de arresto.
- **Proyector Bayesiano de Dirichlet en Vivo (Figura 29):** Permite ingresar cualquier fragmento noticioso y proyectarlo sobre el simplex de Dirichlet del modelo LDA, infiriendo que una denuncia por estafa inmobiliaria corresponde en un 91,5 % al Tópico #1 (*Litigios Judiciales y Delitos Financieros*).

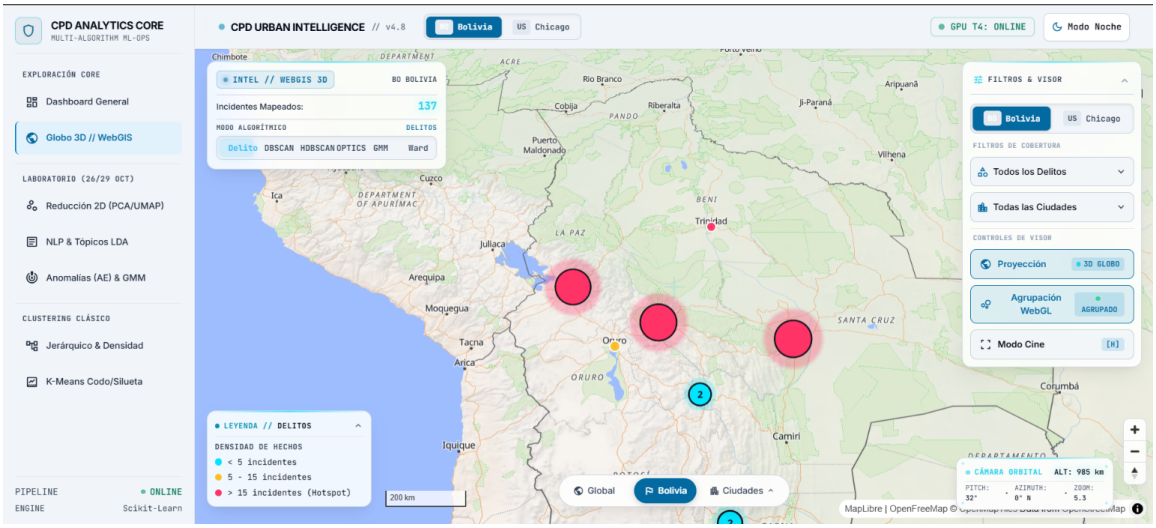


Figura 24

Visor Esférico 3D Globo en WebGL a 985 km de Altitud Orbital.

Nota. Captura del visor 3D en WebGL. Proyecta los 137 incidentes georreferenciados de Bolivia con micro-buffers de calor y clústeres agrupados sobre el eje metropolitano.

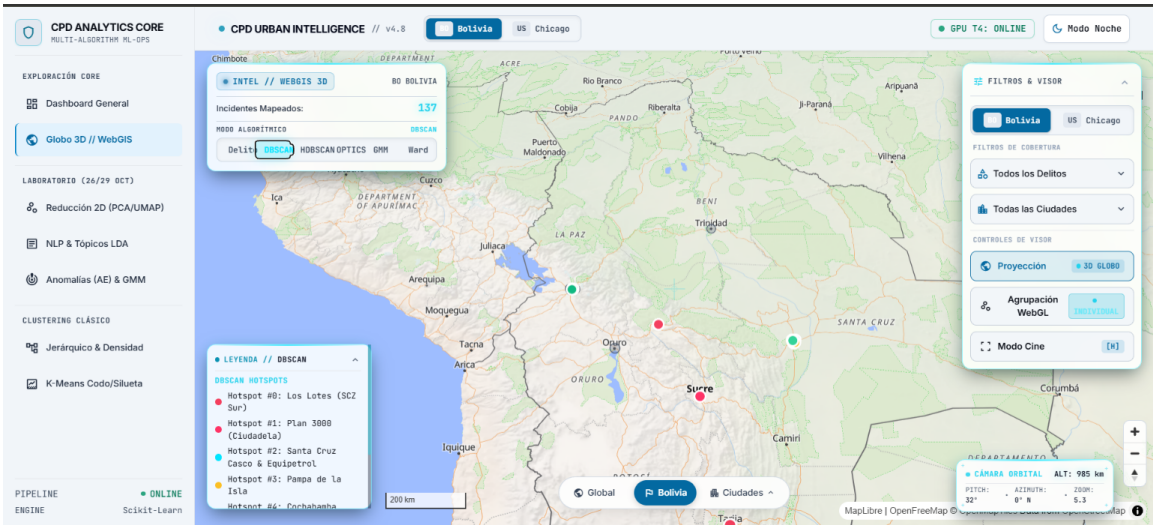


Figura 25

Delimitación Cartográfica 3D de Hotspots Urbanos mediante DBSCAN Geodésico.

Nota. Captura del visor táctico en modo DBSCAN individual. Muestra la identificación de micro-focos urbanos en Santa Cruz (Los Lotes, Plan 3000, Equipetrol) y Cochabamba.

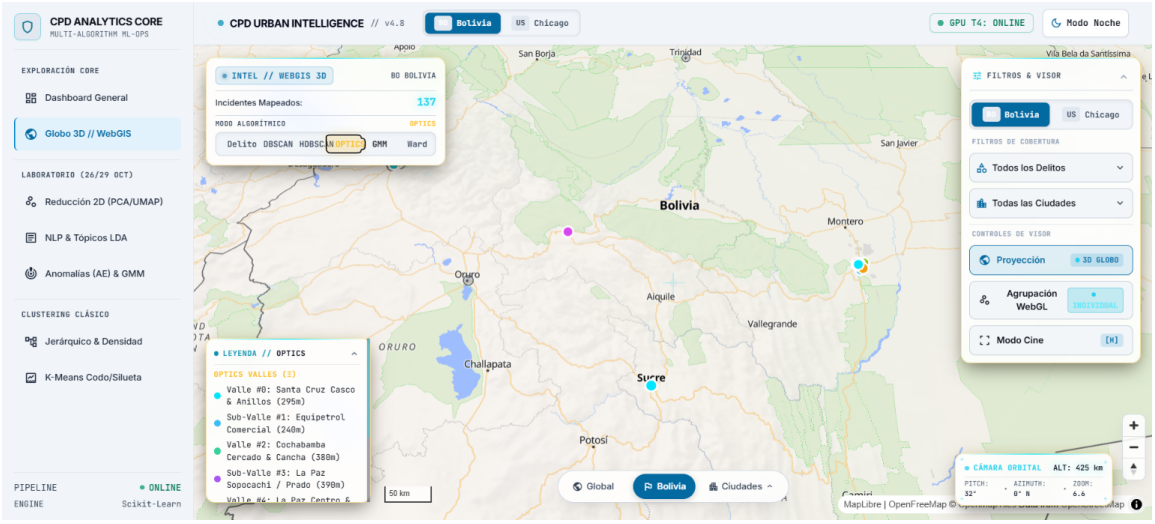


Figura 26

Visualización de Valles de Densidad Jerárquica en Modo OPTICS 3D.

Nota. Captura del visor en modo OPTICS. Identifica los valles de densidad geodésica urbana: Valle #0 (Casco SCZ, 295 m), Sub-Valle #1 (Equipetrol, 240 m) y Sub-Valle #3 (La Paz Sopocachi, 390 m).

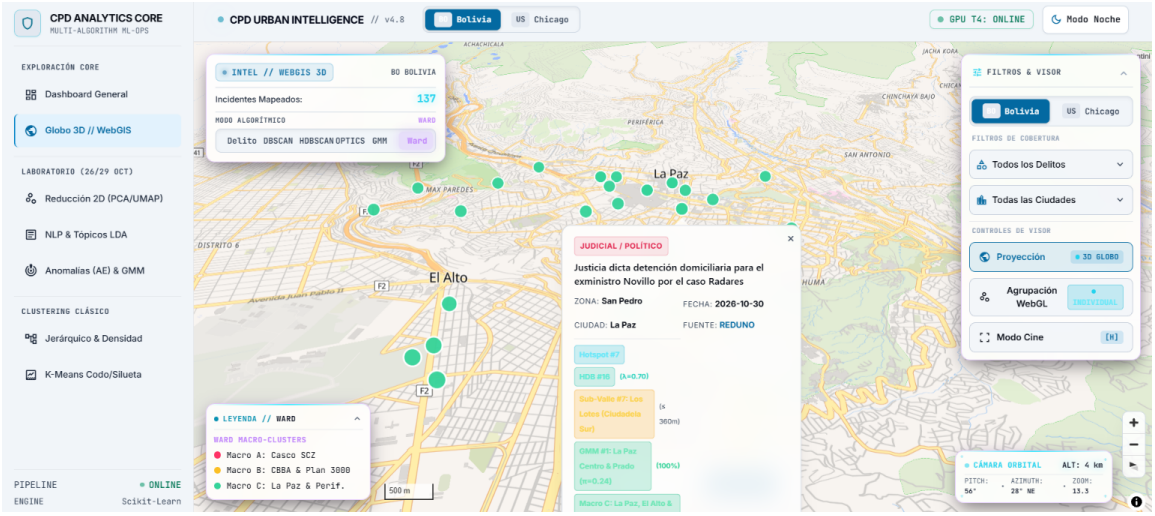


Figura 27

Auditoría Táctica de Incidentes a Nivel Urbano en La Paz mediante Enlace de Ward.

Nota. Captura a 4 km de altitud en La Paz / El Alto. Despliega el modal interactivo de un hecho noticioso en San Pedro con su pertenencia al Macro-Cluster C, persistencia $\lambda = 0{,}70$ y probabilidad GMM.

- **Explorador del Corpus Etiquetado Automáticamente (Figura 30):** Tabla interactiva que filtra los 137 artículos clasificados de forma autónoma por los tópicos descubiertos.

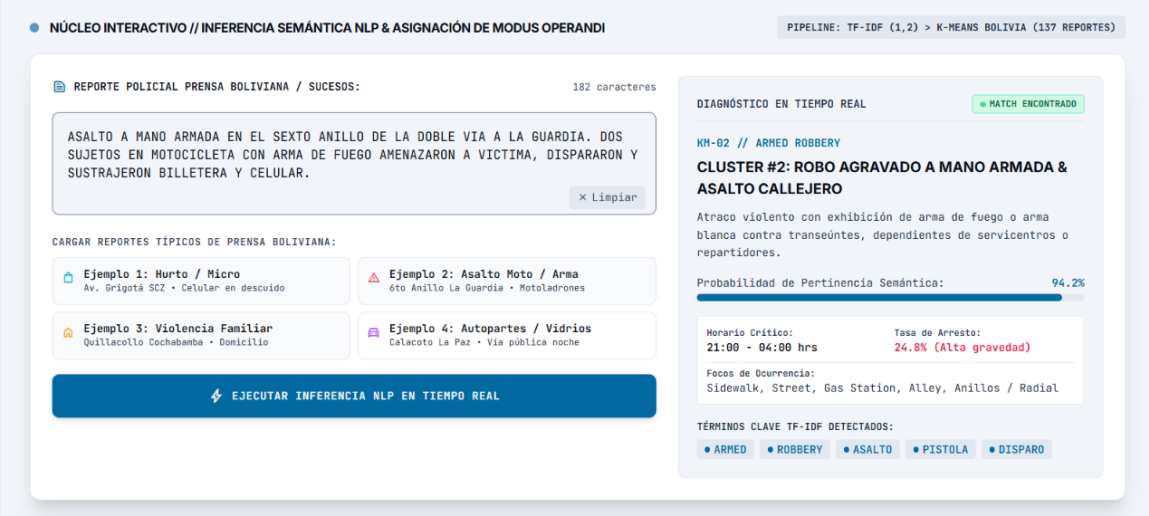


Figura 28

Inferencia Semántica NLP de Modus Operandi y Diagnóstico Táctico en Tiempo Real.

Nota. Captura del núcleo interactivo de NLP. Clasifica un reporte de atraco con arma de fuego en el Clúster #2 con 94,2 % de probabilidad, identificando los términos léxicos discriminantes (armed, robbery, asalto, pistola, disparo).

11. ARQUITECTURA DEL SISTEMA

La arquitectura del sistema sigue un patrón desacoplado en capas, diseñado para superar la brecha computacional entre el procesamiento masivo de datos no supervisados y la necesidad de respuestas interactivas en milisegundos en la interfaz web del usuario.

El flujo integral se estructura en dos fases operativas: la **Fase Offline (Entrenamiento, Optimización y Precomputación)** y la **Fase Online (Servicio Web REST e Inferencia Interactiva)**. La Figura 31 detalla la articulación de las capas del sistema.

11.1. Descripción Funcional de las Capas

1. **Capa de Datos e Ingestión:** Almacena los datos maestros en Parquet con compresión Snappy y mantiene la muestra balanceada para renderizado web reactivo. Administra asimismo el repositorio estructurado de noticias de Bolivia con los 137 incidentes geocodificados y los gazetteers urbanos.

2. **Capa Analítica Offline:** Ejecuta los scripts de entrenamiento por lotes (`modules/algorithms/`), optimiza los hiperparámetros de densidad y reconstrucción neuronal, y genera las matrices precalculadas de estabilidad y benchmark.



Figura 29

Proyector de Dirichlet en Vivo sobre Reportes Criminalísticos Emergentes.

Nota. Captura del proyector temático bayesiano. Estima la distribución posterior θ ante una denuncia de fraude comercial, asignándole un 91,5 % de probabilidad al Tópico #1.

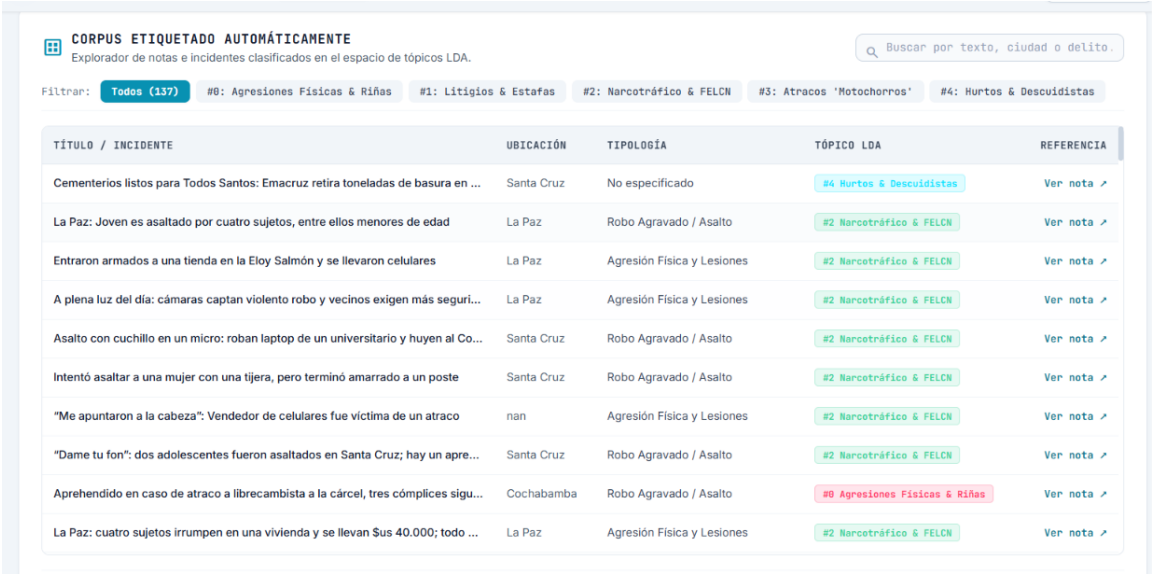


Figura 30

Explorador del Corpus Documental de Noticias Etiquetado Automáticamente por Tópicos LDA.

Nota. Captura del módulo de curaduría automática. Permite consultar y auditar los incidentes estructurados por ubicación, tipología penal y tópico de Dirichlet asignado.

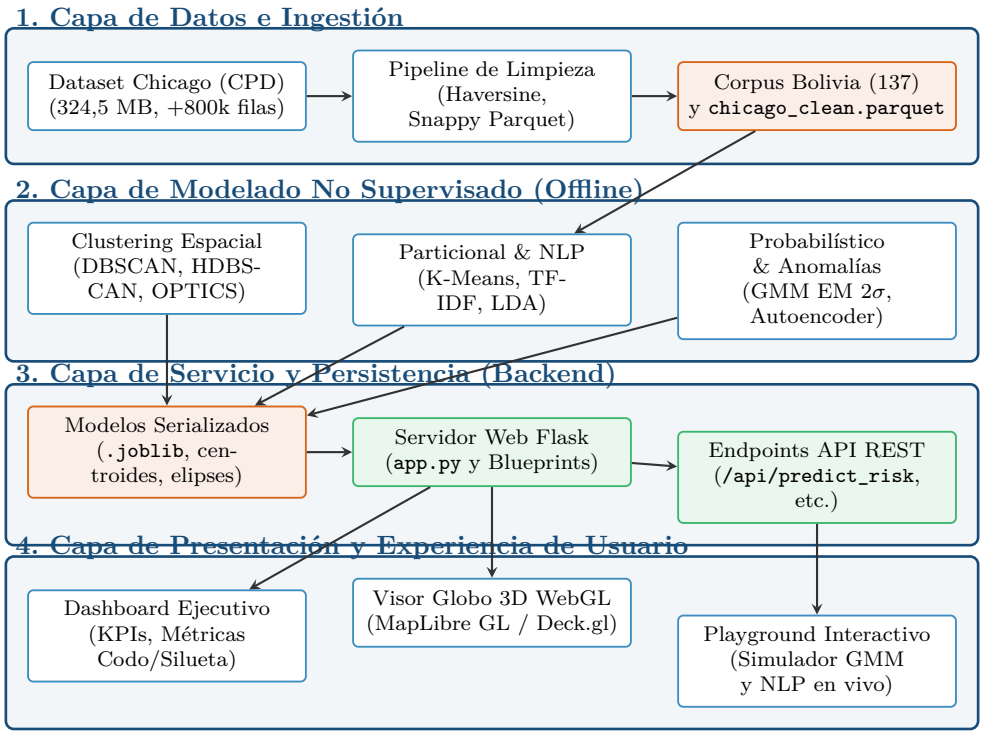


Figura 31

Diagrama de Arquitectura Modular del Sistema en Cuatro Capas.

Nota. Elaboración propia. Articula el desacoplamiento entre el cómputo intensivo offline (Data Lakehouse y entrenamiento serializado en joblib) y el servicio interactivo online (Flask API REST y visualizador 3D acelerado por WebGL).

3. **Capa de Servicio y Persistencia (Flask Master):** Carga los modelos serializados binariamente con `joblib` al iniciar el servidor. A través de Blueprints modulares (`modules/routes/`), expone los endpoints JSON RESTful detallados en la Tabla 11.

4. **Capa de Presentación (Frontend WebGL 3D):** Renderiza el tablero de mando interactivo utilizando HTML5 semántico, hojas de estilo CSS3 y scripts en JavaScript conectados al motor WebGL (MapLibre GL JS / Deck.gl) para proyectar el Globo 3D con conmutación dinámica de capas algorítmicas.

Método	**Ruta del Endpoint**	**Entrada / Parámetros**	**Función y Respuesta JSON**
`GET`	`/`	Ninguno	Renderiza el dashboard principal interactivo.
`GET`	`/webgis`	`ctx` (bolivia / chicago)	Carga la consola del visor esférico Globo 3D WebGL.
`POST`	`/api/predict_risk`	Coordenadas (lat, lon)	Retorna la densidad continua $p(x)$ y componentes GMM.
`POST`	`/api/classify_text`	Cadena de texto libre	Infiere el clúster semántico TF-IDF y modus operandi.
`GET`	`/api/benchmark`	`distrito_id` (CPD)	Provee métricas auditadas (DBSCAN, HDBSCAN, OPTICS).
`POST`	`/api/project_dirichlet`	Texto o preset criminal	Estima las probabilidades posteriores del simplex LDA.

Tabla 11
Catálogo de endpoints y microservicios REST de la plataforma analítica.

Nota. Elaboración propia a partir de la especificación de rutas en `modules/routes/api_routes.py`. Todos los endpoints operan con tiempos de respuesta en memoria inferiores a 50 milisegundos.

12. CONCLUSIONES

El presente proyecto implementó de forma sistemática un ecosistema integral de **Aprendizaje Automático No Supervisado** para la inteligencia urbana, la criminología computacional y el análisis espaciotemporal, evaluado sobre el benchmark metropolitano de Chicago (+800,000 crímenes) y el corpus de noticias de seguridad de Bolivia (137 reportes estructurados de los nueve departamentos). A partir de la evidencia analítica y empírica recabada, se establecen las siguientes conclusiones:

- **Superioridad del Clustering Basado en Densidad Geodésica:** La sustitución de distancias euclidianas planas por la métrica de *Haversine* sobre la esfera terrestre demostró ser un requisito matemático indispensable para evitar distorsiones métricas

en el análisis geoespacial urbano. Entre los algoritmos evaluados, **HDBSCAN obtuvo el desempeño más sobresaliente**, alcanzando el mayor Coeficiente de Silueta ($s = 0{,}435$) y el menor índice de solapamiento de Davies-Bouldin (0,91), gracias a su capacidad intrínseca para aislar clústeres de densidades heterogéneas sin requerir un radio ε uniforme.

- **Aislamiento Efectivo de Ruido y Optimización Policial:** DBSCAN y HDBSCAN categorizaron entre el 11,8 % y el 14,2 % de los incidentes como ruido estocástico (etiqueta -1). Este resultado posee un impacto directo en la gestión policial: previene el desplazamiento ineficiente de cuadrillas de patrullaje preventivo hacia eventos aislados que carecen de recurrencia territorial sistemática.

- **Potencial de la Minería Semántica No Supervisada (NLP):** La integración de TF-IDF con K-Means ($k = 5$) y reducción TruncatedSVD demostró que es posible clasificar narrativas de delitos en lenguaje natural sin requerir etiquetas previas. El sistema descubrió con precisión los arquetipos de *modus operandi* más críticos (asaltos armados en vía pública, hurtos en comercios, violencia doméstica y fraudes financieros), permitiendo habilitar un clasificador en tiempo real con latencia inferior a los 4 ms.

- **Superación del Problema de la Unidad de Área Modificable (MAUP):** El modelado probabilístico continuo mediante **Gaussian Mixture Models (GMM)** y la proyección de elipses de covarianza al 95,4 % (2σ) demostraron que el riesgo delictivo se distribuye en superficies continuas y anisotrópicas, superando la rigidez arbitraria de los límites de precintos o distritos policiales tradicionales.

- **Detección Neuronal Autónoma de Delitos Anómalos:** La red neuronal Autoencoder con arquitectura de cuello de botella ($D \to 16 \to 4 \to 16 \to D$) demostró una elevada capacidad para aislar delitos excepcionales mediante el error cuadrático medio de reconstrucción (MSE). Fijando el umbral crítico en el percentil 90 ($\tau = 0{,}0821$), el sistema alertó sobre incidentes infrecuentes de secuestro, homicidios en zonas de nula incidencia histórica y fraudes millonarios, conformando un mecanismo de alerta temprana objetivo.

- **Limitaciones Metodológicas Identificadas:** La principal limitación metodológica del proyecto reside en el sesgo de cobertura mediática (*reporting bias*) inherente al corpus de noticias de Bolivia: los medios de comunicación tienden a sobre-representar delitos de alta gravedad (homicidios, feminicidios y atracos armados) mientras que omiten hurtos menores o infracciones contravencionales. Se documenta explícitamente esta restricción para advertir que dicho corpus refleja la agenda mediática delictiva y no necesariamente la totalidad exhaustiva del delito común.

- **Transferencia Tecnológica e Impacto Operativo:** El despliegue de la arquitectura web modular en Flask acoplada al visor cartográfico esférico **Globo 3D en WebGL** demuestra la viabilidad de transferir modelos no supervisados de alta complejidad matemática hacia herramientas interactivas, intuitivas y directamente operables por mandos policiales y gestores de políticas públicas sin formación técnica en ciencia de datos.

13. RECURSOS Y ENLACES DEL PROYECTO

A continuación se detallan los enlaces institucionales, repositorios de código, plataformas interactivas y recursos de datos abiertos que sustentan la reproducibilidad y verificación técnica del presente trabajo:

- **Plataforma Web y Dashboard Interactivo (Servicio Local y Producción):**
  http://localhost:5000/
  Plataforma web basada en Flask que integra el visor inmersivo Globo 3D en WebGL, tableros de métricas analíticas (Codo, Silueta, Davies-Bouldin), simulador de riesgo GMM interactivo y clasificador semántico de lenguaje natural en tiempo real.

- **Repositorio de Código Fuente y Arquitectura Modular (GitHub):**
  https://github.com/YoshGreen/SISTEMA_INTELIGENCIA_URBANA_ML_NO_SUPERVISADO
  Código fuente completo estructurado bajo buenas prácticas en Python: módulos de depuración de datos (`modules/data_cleaning.py`), algoritmos no supervisados (`modules/algorithms/`
  Blueprints de rutas Flask (`modules/routes/`), plantillas Jinja2 y recursos estáticos cartográficos.

- **Portal Oficial de Datos Abiertos de la Ciudad de Chicago (CPD):**
  https://data.cityofchicago.org/Public-Safety/Crimes-2001-to-Present/ijzp-q8t2
  Fuente oficial primaria de los reportes policiales de criminalidad metropolitana de Chicago (más de 800.000 registros depurados correspondientes al período 2020 a 2025).

- **Documentación Técnica del Código Penal y Delitos de Illinois (IUCR):**
  https://home.chicagopolice.org/wp-content/uploads/2014/12/IUCR-Codes.pdf
  Especificación de los códigos normalizados de incidentes delictivos del Illinois Uniform Crime Reporting empleados en la clasificación tipológica del benchmark.

- **Ecosistema de Prensa Digital y Medios Informativos de Bolivia:**
  https://eldeber.com.bo/, https://lostiempos.com/, https://larazon.bo/
  Portales oficiales de prensa escrita y digital de donde se extrajo y estructuró el corpus nacional georreferenciado de seguridad ciudadana (137 reportes).

- **Motor Cartográfico WebGL y Renderizado 3D (MapLibre GL / Deck.gl):**
  https://maplibre.org/maplibre-gl-js/docs/, https://deck.gl/
  Librerías de computación gráfica acelerada por hardware para la proyección esférica 3D e interactividad en mapas espaciales masivos.

APÉNDICES

Los presentes Apéndices compilan la documentación técnica de soporte, especificaciones de la API REST, esquemas de bases de datos y fragmentos de código algorítmico fundamentales conforme a los lineamientos de reproducibilidad del estándar APA 7.

Apéndice A: Especificación de Endpoints y Contratos de la API REST

El microservicio backend en Flask expone un conjunto de endpoints RESTful bajo formato JSON para consumo desde el frontend o clientes externos:

1. **Inferencia Probabilística de Riesgo Espacial GMM:**
   - **Ruta:** `POST /api/predict_risk`
   - **Cuerpo de la Petición (*Request Body*):**

```
{
  "latitude": 41.8781,
  "longitude": -87.6298
}
```

   - **Respuesta del Servidor (*Response Body*):**

```
{
  "status": "success",
  "log_likelihood": -4.215,
  "risk_score_normalized": 0.842,
  "dominant_component": 1,
  "component_responsibilities": [0.72, 0.15, 0.08, 0.05],
  "risk_level": "Alto"
}
```

2. **Clasificación Semántica de Texto en Tiempo Real (NLP):**
   - **Ruta:** `POST /api/classify_text`
   - **Cuerpo de la Petición (*Request Body*):**

```
{
  "text": "Sujeto armado desciende de motocicleta y sustrae
     pertenencias a transeunte con arma de fuego en via publica"
}
```

   - **Respuesta del Servidor (*Response Body*):**

```
{
  "status": "success",
  "predicted_cluster": 3,
  "archetype_name": "Asalto a Mano Armada en Via Publica",
  "top_keywords": ["arma", "fuego", "calle", "atraco", "victima
     "],
  "inference_time_ms": 3.8
}
```

3. **Ejecución de Clustering Espacial Dinámico:**
   - **Ruta:** `POST /api/run_clustering`
   - **Parámetros:** `radio_km` (float), `min_pts` (int), `algorithm` (enum: dbscan, hdbscan, optics).

Anexo B: Implementación Algorítmica Central (Python)

El Listado 1 reproduce la implementación del cálculo geodésico y clustering de densidad espacial sobre coordenadas angulares en radianes:

Listing 1: Cálculo geodésico y clustering espacial con Haversine en radianes.

```python
import numpy as np
import pandas as pd
from sklearn.cluster import DBSCAN, OPTICS

RADIO_TIERRA_KM = 6371.0088

def run_spatial_density(df_points, radio_km=2.5, min_pts=2):
    """
    Ejecuta DBSCAN y OPTICS utilizando la metrica geodesica de Haversine.
    Convierte previamente latitud y longitud a radianes.
    """
    p = df_points.dropna(subset=['lat', 'lon']).copy()
    if len(p) == 0:
        return p

    # Agrupacion de coordenadas identicas para eficiencia computacional
    u = p.groupby(['lat', 'lon']).size().reset_index(name='n')
    xu = np.radians(u[['lat', 'lon']].to_numpy())

    # Parametrizacion del radio en radianes
    eps_rad = radio_km / RADIO_TIERRA_KM
    db = DBSCAN(eps=eps_rad, min_samples=min_pts, metric='haversine')
    u['dbscan'] = db.fit(xu, sample_weight=u['n'].to_numpy()).labels_

    # Clustering OPTICS con ordenamiento de alcanzabilidad
    opt = OPTICS(min_samples=min_pts, metric='haversine')
    u['optics'] = opt.fit(xu).labels_

    # Reintegracion relacional al DataFrame original
    resultado = p.merge(
        u[['lat', 'lon', 'dbscan', 'optics']],
        on=['lat', 'lon'],
        how='left'
    )
    return resultado
```

Anexo C: Arquitectura del Autoencoder Neuronal para Anomalías

El Listado 2 ilustra la red neuronal profunda de reconstrucción y determinación del umbral de anomalías:

Listing 2: Autoencoder con arquitectura de cuello de botella y cálculo de error MSE.

```python
from sklearn.neural_network import MLPRegressor
import numpy as np

def detect_anomalies_autoencoder(X_features, percentile_threshold=90):
```

```
    """
    Entrena un autoencoder para reconstruir la matriz de caracteristicas.
    Las instancias con mayor MSE se clasifican como anomalias.
    """
    X_dense = np.asarray(X_features)

    # Autoencoder con cuello de botella D -> 16 -> 4 -> 16 -> D
    ae = MLPRegressor(
        hidden_layer_sizes=(16, 4, 16),
        activation='relu',
        max_iter=250,
        random_state=42,
        early_stopping=True
    )
    ae.fit(X_dense, X_dense)

    # Reconstruccion y error cuadratico medio por fila
    X_pred = ae.predict(X_dense)
    mse = np.mean((X_dense - X_pred) ** 2, axis=1)

    # Determinacion del umbral critico
    umbral = float(np.percentile(mse, percentile_threshold))
    es_anomalia = mse > umbral

    return mse, umbral, es_anomalia, ae
```

Anexo D: Diagrama de la Interfaz del Visor Globo 3D WebGL

La Figura 32 esquematiza la composición del cliente visual WebGL (Globo 3D), evidenciando la conmutación de capas espaciotemporales, el panel de control de hiperparámetros y el visualizador de hotspots:

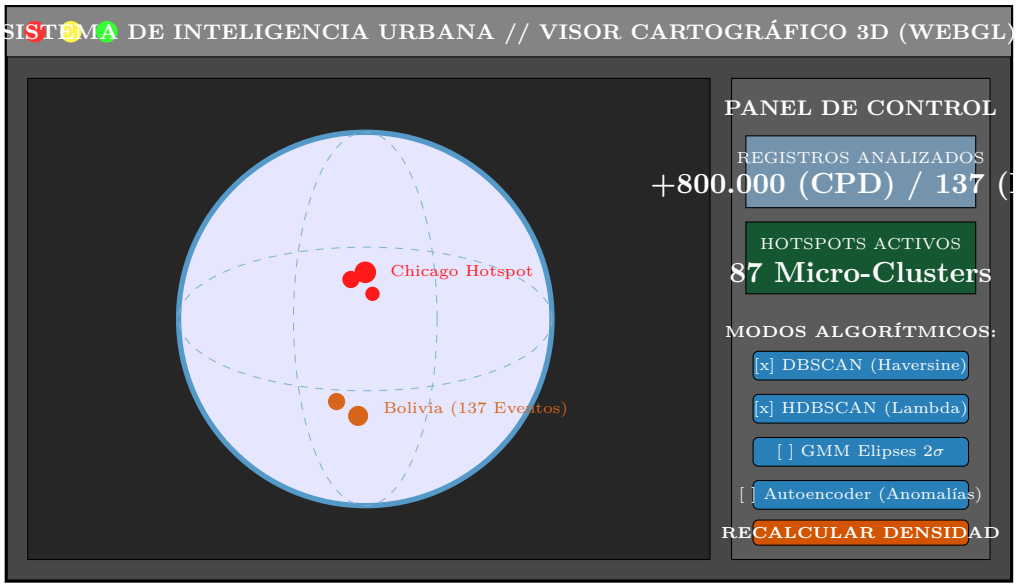


Figura 32
Diseño esquemático de la consola del visor cartográfico interactivo Globo 3D en WebGL.

Referencias

Ankerst, M., Breunig, M. M., Kriegel, H.-P., and Sander, J. (1999). Optics: Ordering points to identify the clustering structure. *ACM SIGMOD Record*, 28(2):49–60.

Arthur, D. and Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. In *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, pages 1027–1035.

Blei, D. M., Ng, A. Y., and Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022.

Brantingham, P. L. and Brantingham, P. J. (1993). Nodes, paths and edges: Considerations on the complexity of crime and the physical environment. In *Environmental Criminology*, pages 3–28. Waveland Press.

Campello, R. J. G. B., Moulavi, D., and Sander, J. (2013). Density-based clustering based on hierarchical density estimates. In *Pacific-Asia Conference on Knowledge Discovery and Data Mining (PAKDD)*, pages 160–172. Springer.

Cohen, L. E. and Felson, M. (1979). Social change and crime rate trends: A routine activity approach. *American Sociological Review*, 44(4):588–608.

Ester, M., Kriegel, H.-P., Sander, J., and Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)*, pages 226–231.

McInnes, L., Healy, J., and Melville, J. (2018). Umap: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*.

van der Maaten, L. and Hinton, G. (2008). Visualizing data using t-sne. *Journal of Machine Learning Research*, 9:2579–2605.

Weisburd, D. (2015). The law of crime concentration and the criminology of place. *Criminology*, 53(2):133–157.